



FAKULTÄT FÜR INFORMATIK
ORGANIC COMPUTING

Vergleich verschiedener Rekombinationsalgorithmen für Cartesian Genetic Programming

Masterarbeit

Cindy Ebertz

Abgabedatum	26. März 2025
Matrikelnummer	1542003
Studiengang	Master Ingenieurinformatik
Gutachter	Prof. Dr. Jörg Hähner Prof. Dr.-Ing. Lars Mikelsons

Zusammenfassung

TODO

Inhaltsverzeichnis

Abbildungsverzeichnis	vii
1 Motivation und Aufbau	1
2 Grundlagen	3
2.1 Aufbau CGP und initiale Population	4
2.2 Evaluation und Selektion	8
2.3 Evolutionärer Operator: Rekombination	9
2.3.1 One-Point Rekombination	9
2.3.2 Two-Point Rekombination	11
2.3.3 Uniform Rekombination	12
2.3.4 Rekombinationsraten	13
2.4 Evolutionärer Operator: Mutation	16
2.5 Evaluation Fitness, Stopp-Kriterium und Ergebnis	18
2.6 Bayes'sche Analyse	18
3 Experimente und Evaluation	21
3.1 Aufbau der Experimente	21
3.1.1 Testszenarien	21
3.1.2 CGP-Konfigurationen	23
3.1.3 Hyperparameteroptimierung	25
3.1.4 Teststruktur	26
3.2 Evaluation	29
4 Ergebnisse	31
4.1 Ergebnisse Rohdatenanalyse	31
4.1.1 Rohdatenanalyse: Parity	32
4.1.2 Rohdatenanalyse: Keijzer	38
4.1.3 Rohdatenanalyse: Encode	43
4.1.4 Rohdatenanalyse: Koza	50
4.1.5 Rohdatenanalyse: Zusammenfassung	56

4.2	Ergebnisse Bayes'sche Analyse	60
4.2.1	Bayes'sche Analyse: Parity	60
4.2.2	Bayes'sche Analyse: Keijzer	61
4.2.3	Bayes'sche Analyse: Encode	62
4.2.4	Bayes'sche Analyse: Koza	65
4.2.5	Bayes'sche Analyse: Zusammenfassung	68
4.3	Ergebnisse Graphische Evaluation	68
4.3.1	Graphische Evaluation: Parity	68
4.3.2	Graphische Evaluation: Keijzer	68
4.3.3	Graphische Evaluation: Encode	68
4.3.4	Graphische Evaluation: Koza	68
4.3.5	Graphische Evaluation: Zusammenfassung	68
5	Fazit aus Ausblick	69
A	Anhang	I
A.1	Plots Parity	I

Abbildungsverzeichnis

2.1	Aufbau CGP, angelehnt an [TST22]	3
2.2	Darstellungsmöglichkeiten eines Chromosoms, angelehnt an [TST22] . . .	4
2.3	One-Point Rekombination, angelehnt an [TST22]	10
2.4	Two-Point Rekombination, angelehnt an [TST22]	11
2.5	Uniform Rekombination, angelehnt an [TST22]	12
2.6	Single Active Mutation, angelehnt an [TST22]	17
2.7	Bayes'sche Analyse, angelehnt an [Nen80]	19
4.1	Encode: Raten-Arten und Anzahl positive Rekombinationen	49
4.2	Koza: Raten-Arten und Anzahl positive Rekombinationen	55

1 Motivation und Aufbau

Das klassische Genetic Programming (GP) wird heutzutage für die Problemlösung in den unterschiedlichsten Domänen erforscht. Beispiele hierfür sind die Erstellung einer mathematischen Gleichung für einen industriellen Prozess [SB01], die Strukturanalyse von FGMs (funktionell gradierten Materialien) [Dem+22] und der Verarbeitung von natürlicher Sprache [Ara20].

Cartesian Genetic Programming (CGP) ist eine Methode des GPs, in der Lösungen für Probleme als Graphen dargestellt werden [Mil20]. Im Standard-CGP werde laut Miller der Rekombinationsschritt normalerweise nicht ausgeführt und in den meisten Arbeiten werde dieser Schritt gänzlich ignoriert. Er bezieht dieses Verhalten auf Forschungsergebnisse aus dem Jahr 1999, die nach Miller aufzeigen, dass der Rekombinationsschritt kaum einen Effekt auf die Effizienz von CPG hat. [Mil20] In mehreren weiteren Papern werden andere Rekombinationsalgorithmen mit dem Ziel vorgestellt, dass der Rekombinationsschritt neben der Mutation sinnvoll in CGP eingebaut werden kann. Dieser weitere Operator könnte die Effizienz von CGP-Modellen im Training steigern und somit komplexere Ausgangsprobleme lösbar machen. Innerhalb dieser Paper wird als Prämisse angenommen, dass wie von Miller geschildert in Standard-CGP keine Rekombination verwendet wird. [CWM07; Kal20; TST22]

Da die Aussage, dass der Rekombinationsschritt nicht zielführend in Standard-CGP sei auf den Papern von Miller aus dem Jahr 1999 und 2011 basiert, kommt die Frage auf, ob dies immer noch zutrifft. Die erste Forschungsfrage, die in dieser Arbeit beantwortet werden soll, ist demnach die folgende: „Kann mit heutigem Forschungsstand nachgewiesen werden, dass Rekombination in Standard-CGP sinnvoll eingesetzt werden kann im Vergleich zu CGP ohne Rekombinationsschritt?“

Da der Erfolg der Rekombination ebenfalls von der Rekombinationsrate abhängt, ist es sinnvoll diese näher zu betrachten. Clegg et al. und Torabi et al. beschreiben in ihren Papern unterschiedliche Herangehensweisen an die Rekombinationsrate [CWM07; TST22]: Clegg et al. führen eine variable Rekombinationsrate in ihrem Paper ein. Dabei wird eine

hohe Rekombinationsrate linear verringert, sodass in den letzten Lernschritten keine Rekombination mehr ausgeführt wird. [CWM07]

Torabi et al. fügen für ihre Rekombination ein Offset zu Beginn des CGP ein. Dieser Offset wird durch einen Hyperparameter bestimmt und gibt an, wie viele Iterationen die Rekombination ausbleibt. [TST22]

Diese beiden Ansätze sollen mit einem selbst entwickelten Ansatz verglichen werden. Die neu vorgestellte Rekombinationsrate bezieht sich auf die One-Fifth-Rule zur Berechnung der Mutationsrate. Die zweite Forschungsfrage, die in dieser Arbeit beantwortet werden soll, ist: „Hat die Art und Weise der Rekombinationsratenberechnung eine Auswirkung auf die Effektivität des CGP?“

Die beiden Forschungsfragen sollen anhand unterschiedlicher Experimente beantwortet werden. In Abschnitt 2 werden die theoretischen Grundlagen gelegt, die für das Verständnis des Experimentaufbaus und der Ergebnisse benötigt werden. Im Anschluss werden in Abschnitt 3 die jeweiligen Experimente, sowie die Evaluationsstrategien der Ergebnisse beschrieben. Darauf folgend werden in Abschnitt 4 die Ergebnisse der Experimente vorgestellt und ausgewertet. Abschließend wird in Abschnitt 5 ein Fazit aus den Ergebnissen zusammengefasst, sowie ein Ausblick auf weitere mögliche Forschungsfragen gegeben.

2 Grundlagen

Für den praktischen Teil dieser Arbeit in Abschnitt 3 werden mit Hilfe von CGP unterschiedliche Testprobleme gelöst. Für das Verständnis dieses Teil werden einige Grundkenntnisse vorausgesetzt, welche in diesem Abschnitt näher betrachtet werden.

CGP ist eine Art von GP, welches verwendet wird, um unterschiedliche Probleme zu lösen. Dabei wird der Maschine allerdings nicht beigebracht, wie diese Probleme zu lösen sind. Stattdessen lernt sie eigenständig über mehrere Iterationen hinweg das Ausgangsproblem zu lösen. Dies geschieht angelehnt an die Darwin'sche Theorie der biologischen Evolution. [Ahv+19]

Um den grundlegenden Aufbau von CGP zu erläutern, wird folgende Abbildung 2.1 eingeführt:



Abbildung 2.1: Aufbau CGP, angelehnt an [TST22]

Die Abbildung 2.1 zeigt den grundlegenden Ablauf innerhalb von CGP. Dabei lernt das System über mehrere Iterationen hinweg die beste Lösung eines Problems. Die folgenden Unterkapitel beziehen sich jeweils auf einen Knoten des Graphen und erläutern diesen genauer.

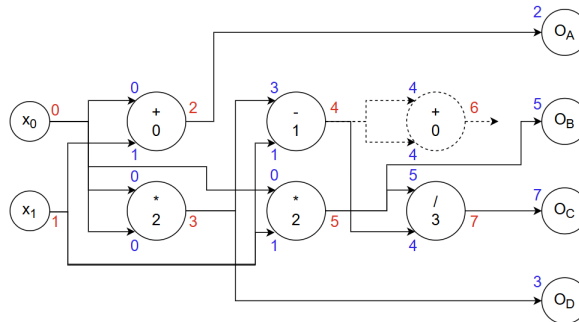
2.1 Aufbau CGP und initiale Population

Dieser Abschnitt bezieht sich auf die Paper [Mil20], [TST22] und [Ahv+19]. Außerdem werden Erkenntnisse aus dem Quellcode von Cui verwendet [Cui24b].

Die *Population* von CGP ist eine Menge von *Chromosomen*, auch Individuen genannt. Chromosome sind individuelle Möglichkeiten ein komplexes Ausgangsproblem zu lösen. Jedes Chromosom ist in CGP ein gerichteter, azyklischer Graph, bestehend aus *Eingangsknoten*, *Rechenknoten* und *Ausgangsknoten*. Dabei gibt es zwei Darstellungsmöglichkeiten für ein Chromosom. Anhand der folgenden Abbildung 2.2 kann beispielhaft näher erläutert werden, wie die Chromosome in CGP aufgebaut sind und funktionieren.



(a) Beispiel Genotyp



(b) Beispiel Phänotyp

Abbildung 2.2: Darstellungsmöglichkeiten eines Chromosoms, angelehnt an [TST22]

Anhand Abbildung 2.2b lässt sich die klassische Struktur von CGP erkennen: Es handelt sich um einen gerichteten, azyklischen Graphen mit Ein- und Ausgängen. In diesem Beispiel werden die beiden Systemeingänge x_0 und x_1 vorausgesetzt, welche durch Eingangsknoten zur Verfügung gestellt werden. Aus diesen Eingaben sollen anschließend durch verschiedene Berechnungen die Ausgänge resultieren. In diesem Fall werden vier Systemausgänge berechnet, die durch die Ausgangsknoten $O_A - O_D$ dargestellt werden. Zwischen den Ein- und Ausgangsknoten liegen die Rechenknoten. Diese werden verwendet, um verschiedene Rechenoperationen an den Eingangsknoten auszuführen, bis schließlich die Inhalte der Ausgangsknoten als Ergebnis resultieren. Die Rechenoperationen, die von den Rechenknoten ausgeführt werden, werden je nach Anwendungsfall definiert und codiert. In diesem Beispiel ergibt sich folgende Kodierung:

Rechenoperation	Kodierung
+	0
-	1
*	2
/	3

Tabelle 2.1: Kodierung der Rechenoperationen

Diese Kodierungen werden in Abbildung 2.2b innerhalb der Knoten angegeben und stellen die erste (unterstrichene) Zahl innerhalb des Arrays in Abbildung 2.2a dar. Die umrandeten Teile des gesamten Arrays stellen jeweils einen Knoten des Graphen dar und werden folgend Array-Blöcke genannt. Unterhalb dieser Array-Blöcke wird jeweils der Index des zugehörigen Knotens angegeben. Im CGP-Graph wird dieser Index am Ausgang des jeweiligen Knotens (rot) angezeigt.

Des Weiteren werden in Abbildung 2.2a die Eingangskanten für jeden Knoten angegeben. In diesem Beispiel hat jeder Rechenknoten zwei Eingänge und jeder Ausgangsknoten hat jeweils nur einen Eingang, in dem das Ergebnis eines Rechenknoten weitergeleitet und ausgegeben wird. Die Knoteneingänge sind in Abbildung 2.2b blau markiert. Hier werden die Indices derjenigen Knoten angegeben, deren Ausgangswerte verwendet werden. Diese spiegeln sich ebenfalls in Abbildung 2.2a wider: hier werden die Knoteneingänge innerhalb der Array-Blöcke als nicht-unterstrichene Indices angegeben. Damit ergibt sich eine vollständige Beschreibung eines Knotens: einem Index werden Eingänge und gegebenenfalls eine Rechenoperation zugeschrieben.

Durch dieses Beispiel wird ebenfalls ersichtlich, was die Eingangsknoten eines Chromosoms ausmacht: Sie geben die Systemeingänge wieder, ohne diese auf irgendeine Weise zu

verarbeiten. Aus diesem Grund müssen die Eingangsknoten nicht im Genotyp aufgezeigt werden, um sie vollständig zu beschreiben, denn sie weisen weder Eingänge noch Rechenoperationen auf, die beschrieben werden müssten.

Die beiden Darstellungsmöglichkeiten eines Chromosoms werden wie in Abbildung 2.2 *Genotyp* und *Phänotyp* genannt. Der Phänotyp resultiert dabei aus dem Genotyp. Der Genotyp ist das volle Individuum, während der Phänotyp die Dekodierung dessen ist. Die Lösung des CGPs ist dementsprechend ein Phänotyp, also die Dekodierung des besten Individuums des CGPs. Der Genotyp- und Phänotyp-Raum können sich dabei stark voneinander unterscheiden. [ES15] Dies lässt sich dadurch erklären, dass nicht alle Teile des Genotyps für die Berechnung des Endergebnisses verwendet werden. Diejenigen Anteile, die für die Berechnung der Lösung nicht gebraucht werden, werden *inaktive Knoten* genannt. So ein inaktiver Knoten wird in Abbildung 2.2a durch gestrichelte Linien dargestellt. Da der Phänotyp die Lösung des CGPs ist, müssen inaktive Knoten auch nicht im Phänotyp dargestellt werden, da diese für die Berechnung keine Verwendung finden. Der Vollständigkeit halber wird der inaktive Knoten aus Abbildung 2.2a auch in Abbildung 2.2b aufgenommen. So können also verschiedene Genotypen zum gleichen Phänotyp führen, indem sich verschiedene Genotypen nur anhand ihrer inaktiven Knoten unterscheiden. Da der Phänotyp auch den auszuführenden Programmcode darstellt, können auch verschiedene Genotypen zum gleichen Ergebnis führen. Dies kann die Weiterentwicklung der Chromosomen stören, indem beispielsweise nur inaktive Knoten eines Chromosoms angepasst werden. Das kann sich wiederum negativ auf die Trainingsdauer auswirken. Eine nähere Erklärung wird in Abschnitt 2.4 gegeben.

Ob ein Knoten für die Berechnung der Lösung verwendet wird oder nicht, hängt davon ab, ob ein nachfolgender Knoten auf dessen Ausgang zugreift. Um aktive Knoten von inaktiven Knoten zu unterscheiden, werden demnach zuerst die Ausgangsknoten betrachtet, die offensichtlich für die Auswertung der Ausgabe verwendet werden. Anschließend werden iterativ die Eingangskanten der Rechenknoten zurückverfolgt, bis man schließlich bei den Eingangsknoten des Graphen ankommt.

Schließlich soll anhand der eingeführten Abbildungen 2.2a und 2.2b ein Beispiel berechnet werden:

Angenommen werden die Systemeingänge $x_0 = 10$ und $x_1 = 20$. Demnach sind die Ausgänge der beiden Eingangsknoten mit den Indices 0 und 1 gleich den Werten 10 und 20. Der erste Rechenknoten (Index = 2) verwendet als Eingänge die beiden Eingangsknoten (Indices = 0 und 1) und besitzt die Rechenfunktion $+$. Demnach ist das Ergebnis des Re-

chenknotens $10 + 20 = 30$. Führt man dieses Vorgehen für die restlichen Rechenknoten aus, ergeben sich folgende Ergebnisse:

Knoten	Eingänge	Werte Eingänge	Rechenoperation	Ausgangswert
2	0; 1	10; 20	$10 + 20$	30
3	0; 0	10; 10	$10 * 10$	100
4	3; 1	100; 20	$100 - 20$	80
5	0; 1	10; 20	$10 * 20$	200
7	5; 4	200; 80	$200 / 80$	2,5

Tabelle 2.2: Ergebnisse Rechenknoten

Die Ausgangsknoten geben die jeweiligen Ergebnisse der Eingangs- oder Rechenknoten zurück. In diesem Beispiel werden durch das Chromosom die folgenden Ausgänge aus den beiden Eingängen (10; 20) berechnet:

Ausgangsknoten	Index Eingang	Wert des Ausgangsknotens
O_A	2	30
O_B	5	200
O_C	7	2,5
O_D	3	100

Tabelle 2.3: Ergebnisse Ausgangsknoten

Zusammengefasst hat das Beispielchromosom aus dem Eingangstupel (10; 20) ein Ausgangstupel (30; 200; 2,5; 100) berechnet.

Wie bereits erläutert, ist die Population in CGP eine Menge an Chromosomen, also eine Menge an gerichteten, azyklischen Graphen, die aus definierten Systemeingaben Ausgaben berechnen können. Diese Population wird zu Beginn zufällig initialisiert. Dabei werden folgende Angaben vorausgesetzt:

- Größe der Population
- Anzahl der Systemeingänge
- Anzahl der Systemausgänge

- Anzahl der Rechenknoten pro Chromosom

Im Initialisierungsprozess werden für jedes Chromosom pro Knoten zufällige Eingangskanten und gegebenenfalls Rechenoperationen bestimmt. Dabei muss beachtet werden, dass es sich anschließend um einen azyklischen Graphen handeln muss.

Nachdem die initiale Population erstellt wurde, erfolgt der erste *Evaluations-* und *Selektions-*schritt. Der folgende Abschnitt 2.2 erläutert, wie diese Schritte ausgeführt werden.

2.2 Evaluation und Selektion

Der erste Selektionsschritt in CGP startet mit einer zufällig initialisierten Population, wie sie in Abschnitt 2.1 beschrieben wird. In dieser initialen Population ist die Performance der einzelnen Individuen rein zufällig. Das Ziel von CGP ist es, die Performance über Generationen hinweg zu verbessern, bis schließlich eine (nahezu) perfekte Lösung eines Problems gefunden wird. GP im Allgemeinen richtet sich nach dem darwin'schen Prinzip des Überlebens der Stärkeren. Demnach werden die performantesten Chromosomen verwendet, um die nächste Generation der Population zu erzeugen. [Koz95]

Um zu bestimmen, welche Individuen die beste Performance aufweisen, muss eine numerische Bewertung erfolgen. Diese wird durch die *Fitness* der einzelnen Chromosomen bestimmt. [Koz95] Wie der Fitnesswert berechnet wird, hängt von den zu lösenden Problemen ab. Beispielsweise verwenden Cui et al. für symbolische Regressionsprobleme den mittleren absoluten Fehler zwischen korrekter Lösung und tatsächlicher Lösung für einen Evaluationsdatensatz. [CHH24]

Koza beschreibt in seinem Paper, dass für die Selektion der Eltern der nächsten Generation, jedem Chromosom ein Wahrscheinlichkeitswert zugewiesen wird. Dieser hängt von dessen Fitness ab. Anschließend wird eine definierte Anzahl an Eltern selektiert, wobei die Wahrscheinlichkeitswerte dafür sorgen, dass fittere Individuen die größere Chance haben, selektiert zu werden. Selektion heißt dabei, dass das Chromosom unverändert in die nächste Generation kopiert wird. [Koz95]

Dies ist ein Weg dafür zu sorgen, dass das Prinzip nach Darwin eingehalten wird und somit die fitteren Chromosomen „überleben“. Eine andere Möglichkeit, dies zu erreichen, ist die Verwendung von sogenannten *Elitisten*. Die fittesten Individuen einer Generation werden

dabei als Elitisten erwählt und werden für die folgende Generation selektiert. [Kra+13] Für die Auswahl der Elitisten wird in dieser Arbeit der *neutral search Algorithmus* verwendet. Dieser wird relevant, falls innerhalb einer Generation ein Elter-Chromosom und ein Kind-Chromosom die gleiche Fitness aufweisen. In diesem Fall wird stets das Kind-Chromosom als Elitist ausgewählt. Dies führt dazu, dass anschließend bessere Nachkommen erzeugt werden können. [CMH22]

Mit dem in dieser Arbeit verwendeten Selektionsverfahren namens $(\mu + \lambda)$ -*Evolution Strategy* (ES) wird dieser Ansatz verfolgt. Dabei werden jeweils μ -viele Eltern für die folgende Generation selektiert. Im Standard-CGP wird μ mit 1 belegt. Die restlichen Individuen der Population (λ -viele) werden anschließend durch *Mutation* aus dem Elter-Chromosom gebildet. [SB18] Da für den *Rekombinationsschritt* jeweils zwei Eltern-Chromosomen gekreuzt werden, muss, falls Rekombination ausgeführt wird, für μ ein Wert größer als 1 gewählt werden. Um eine bessere Vergleichbarkeit zu gewährleisten, werden im praktischen Teil auch unterschiedliche μ -Werte gewählt, selbst wenn keine Rekombination ausgeführt wird.

Wie Mutation und Rekombination ausgeführt werden, wird in folgenden Abschnitten 2.3 und 2.4 erläutert.

2.3 Evolutionärer Operator: Rekombination

Nachdem die Selektion der Eltern-Chromosome erfolgt ist, wie in Abschnitt 2.2 beschrieben, können im nächsten Schritt die evolutionären Operationen ausgeführt werden, die die Nachkommen aus den Eltern erzeugen.

Der erste evolutionäre Operator, der verwendet wird, ist die Rekombination. Dabei werden jeweils zwei zufällig ausgewählte Eltern-Chromosomen kombiniert und somit zwei neue (Nachkommen-)Chromosomen erzeugt [Kal20]. Dieser Rekombinationsschritt wird so oft ausgeführt, bis die Population dieser Generation gefüllt ist.


Innerhalb dieser Arbeit werden unterschiedliche Standard-Rekombinationsalgorithmen für die Nachwuchserzeugung miteinander verglichen. Die folgenden Absätze erläutern diese näher.

2.3.1 One-Point Rekombination


Das erste Standard-Rekombinationsverfahren, das in dieser Arbeit verwendet wird, ist die *One-Point Rekombination*, auf die im Folgenden näher eingegangen wird. Für die Grundlagen, die in diesem Abschnitt erläutert werden, wurde folgende Quelle verwendet: [PG17]

2 Grundlagen

Der One-Point Rekombinationsalgorithmus soll anhand folgender Beispielabbildung 2.3 erläutert werden:



(a) Eltern-Chromosomen One-Point Rekombination



(b) Nachwuchs-Chromosomen One-Point Rekombination

Abbildung 2.3: One-Point Rekombination, angelehnt an [TST22]


Das erste Eltern-Chromosom (E1, rot) in diesem Beispiel wurde aus Abbildung 2.2a entnommen. Das zweite Eltern-Chromosom (E2, blau) ist ein zufällig gewähltes Beispielchromosom.

Bei beiden Chromosomen wird vorerst nicht weiter betrachtet, ob die Knoten aktiv oder inaktiv sind, da sich dieses Merkmal mit der Rekombination und Mutation ändern kann. Angenommen wird, dass C1 und C2 aus der letzten Generation übernommen wurden, da sie die beste Fitness aufgewiesen haben.


Für die One-Point Rekombination wird zuerst eine zufällige Stelle innerhalb der Eltern-Chromosomen bestimmt. Diese ist in Abbildung 2.3a grün markiert. Die Eltern-Chromosomen werden anschließend an dieser Stelle geteilt und überkreuzt zusammengesetzt. Für dieses Beispiel ergeben sich die beiden Nachwuchs-Chromosomen aus Abbildung 2.3b.

2.3.2 Two-Point Rekombination

Für die Grundlagen dieses Abschnitts wurde [PG17] als Quelle verwendet. Das Verfahren der *Two-Point Rekombination* funktioniert identisch zur in Abschnitt 2.3.1 erläuterten One-Point Rekombination, mit dem Unterschied, dass zwei zufällige Stellen ausgewählt werden, an denen die Chromosomen geteilt werden. Anhand des nachfolgenden Beispiels kann dies nachvollzogen werden:



(a) Eltern-Chromosomen Two-Point Rekombination



(b) Nachwuchs-Chromosomen Two-Point Rekombination


Abbildung 2.4: Two-Point Rekombination, angelehnt an [TST22]

Zu beobachten ist, dass die Eltern-Chromosomen an jeweils zwei Stellen aufgeteilt werden (grün). Die Nachwuchs-Chromosomen bilden sich anschließend abwechselnd aus den Teilstücken der beiden Eltern-Chromosomen. In der Abbildung 2.4 wird dieser Prozess deutlich, indem die Chromosomenteile des ersten Elternteils rot markiert sind und des zweiten blau.


2.3.3 Uniform Rekombination

Die Erläuterung der *Uniform Rekombination* basiert auf [Sys89].

Was die Uniform Rekombination von der One-Point oder Two-Point Rekombination abhebt, ist die Verwendung einer Maske. Die Maske ist genauso lang wie die Eltern-Chromosomen und beinhaltet für jede Stelle binäre Werte. Diese Werte geben jeweils an, von welchem Elternteil die jeweilige Stelle im Chromosom des Nachwuchses stammen soll. Der zweite gebildete Nachwuchs bekommt in diesem Prozess das Gen des jeweils anderen Elternteils. Anhand der Abbildung 2.5 lässt sich die Uniform Rekombination beispielhaft erklären:



(a) Eltern-Chromosomen Uniform Rekombination



(b) Nachwuchs-Chromosomen Uniform Rekombination

Abbildung 2.5: Uniform Rekombination, angelehnt an [TST22]

Abbildung 2.5a zeigt die Ausgangssituation mit den beiden Eltern-Chromosomen (E1 und E2) in rot und blau. Zwischen den beiden Eltern-Chromosomen wird schwarz die Maske angezeigt. Diese wird zufällig binär gefüllt, bis sie die Länge der beiden Eltern-Chromosomen erreicht.

Im folgenden Schritt werden die Nachwuchs-Chromosomen anhand der Maske erzeugt. Der entsprechende Index des Knotens kann jeweils unterhalb der Eltern-Chromosomen abgelesen werden. Für den ersten Wert der Maske ergibt das den Knotenindex 2. In diesem Beispiel enthält der erste Wert der Maske eine 0. Dementsprechend wird für den Knoten mit dem Index 2 des ersten Nachwuchs-Chromosoms (N1) der jeweilige Knoten des ersten Eltern-Chromosoms (E1, rot) verwendet. Das zweite Nachwuchs-Chromosom (N2) bekommt demnach den entsprechenden Knoten aus dem zweiten Eltern-Chromosom (E2, blau).

Für den darauffolgenden Index hat die Maske den Wert 1. Dies bedeutet, dass die Vererbungen genau andersherum ablaufen: N1 bekommt den Knoten von E2 und N2 bekommt den Knoten von E1. Dieser Prozess wird für alle Indices ausgeführt. Die Abbildung 2.5b zeigt die resultierenden Ergebnisse für dieses Beispiel der Uniform Rekombination.

2.3.4 Rekombinationsraten

In den letzten Abschnitten wurden unterschiedliche Rekombinationsalgorithmen erläutert. Der Rekombinationsschritt wird allerdings nicht für jedes Nachwuchs-Chromosom verwendet. Dieser wird nur zu einer bestimmten Wahrscheinlichkeit ausgeführt, welche mit der *Rekombinationsrate* beschrieben wird. Die Effektivität des (C)GP-Systems hängt unter anderem von der richtigen Wahl der Rekombinationsrate ab. [Has+19]

Um das bestmögliche (C)GP-System zu erhalten, sollte das richtige Verhältnis aus *Exploration* (dt. Erforschung) und *Exploitation* (dt. Ausbeutung) des Lösungsraums erzielt werden. Exploration ist dabei der Prozess, neue Bereiche des Lösungsraums zu erkunden, während bei der Exploitation bereits erkundete Regionen des Lösungsraums näher betrachtet werden. Eine Stellschraube, um den eigenen Prozess dahingehend zu steuern, ist die Rekombinationsrate. [ČLM13] Wird die Rekombinationsrate sehr hoch eingestellt, wird zu einem hohen Maß Exploration betrieben. Dies führt allerdings dazu, dass die Exploitation niedrig gehalten wird und somit die optimalen Lösungen verfehlt werden. [PG17]

In unterschiedlichen Papern werden verschiedene Herangehensweisen vorgeschlagen, diesen Parameter zu wählen. Teilweise widersprechen sich diese Aussagen. Ziel dieser Arbeit ist es, unter anderem einen Einblick zu bekommen, wie man die Rekombinationsrate richtig wählen kann und welche Auswirkungen sie auf die Güte von CGP-Lösungen hat.

Die folgenden Abschnitte geben einen Einblick über die unterschiedlichen Möglichkeiten, die Rekombinationsrate zu belegen.

Konstante Rekombinationsrate

Wie von Hassanat et al. beschrieben, ist die konstante (statische) Rekombinationsrate die übliche Form. Als geläufiges Beispiel wird in ihrem Paper der Wert 0,9 für die Rekombinationsrate vergeben. [Has+19] Dies bedeutet, dass zur Initialisierung des CGP ein fester Wert für die Rekombinationsrate gewählt wird. Dieser gilt für alle Generationen gleichermaßen und wird nicht verändert.

Diese „klassische“ Form der Rekombination kann in der Evaluation der praktischen Tests dazu verwendet werden, um die erste Forschungsfrage zu beantworten. Durch diese einfachste Form der Rekombinationsrate kann überprüft werden, ob CGPs ohne oder mit (klassischer) Rekombination effizienter sind.

Mit Hilfe der in den nächsten Abschnitten folgenden Anpassungen der Rekombinationsrate kann anschließend überprüft werden, ob die Effizienz von CGP mit Rekombination weiter verbessert werden kann.

Linear fallende Rekombinationsrate

Clegg et al. präsentieren in ihrem Paper aus 2007 eine neue Form der Rekombination. Dabei treffen sie auch einige Aussagen über die Rekombinationsrate, die in diesem Abschnitt näher betrachtet werden sollen. [CWM07]

Sie beobachten, dass sich für höhere Rekombinationsraten eine schnellere Konvergenz der Fitness innerhalb der ersten Generationen einstellt. Gleichzeitig stellen sie fest, dass in ihrem Beispiel ab der 200. Generation Rekombination keinen signifikanten Vorteil mehr in der Performance liefert.

Aus diesen beiden Beobachtungen konstruieren sie eine neue, dynamische Rekombinationsrate. Diese beginnt bei einem hohen Startwert von 0,9 und sinkt linear, bis eine Rekombinationsrate von 0,0 erreicht wird. In ihrem Beispiel legen sie über händische Analysen eine Generation fest, bis zu welcher die Rekombinationsrate auf 0,0 fallen soll.

Innerhalb des praktischen Teils dieser Arbeit wird 0,9 für den Startwert der Rekombinationsrate übernommen, um die Anzahl der Parameter in der Hyperparameteranalyse zu reduzieren. Ebenfalls ist es ein Vorteil, nur einen variablen Parameter pro Rekombinationsraten-Typ zu verwenden, da gegebenenfalls die Änderungen innerhalb der Ergebnisse für die verschiedenen Parameter besser miteinander verglichen werden können.

Der einzige variable Parameter für die linear fallende Rekombinationsrate ist in dieser Arbeit die Rate, die nach jeder Generation von der alten Rekombinationsrate abgezogen werden soll, um die neue Rekombinationsrate zu erhalten.

One-Fifth-Regel angewandt auf die Rekombinationsrate

Die *One-Fifth-Regel* gibt es bereits andere Parameter von GP, wie beispielsweise für die *Mutationsrate*, die in Abschnitt 2.4 näher erläutert wird. Diese Regel wird ebenfalls im Paper von Milano und Nolfi verwendet. Dabei handelt es sich um einen Weg, die Mutationsrate automatisch und dynamisch an die Problemcharakteristiken und die evolutionäre Phase anzupassen. [MN18]

Betrachtet wird bei dieser Regel das Fitness-Verhältnis der Elitisten und der neuen Chromosomen. In anderen Worten werden die Kinder also mit ihren Eltern verglichen. Erzielt werden soll ein Verhältnis von 20%. Das heißt, dass 20% der Nachwuchs-Chromosomen eine bessere Fitness aufweisen sollen als ihre Eltern. Wird dieses Verhältnis unter- oder übertroffen, wird der jeweilige Parameter verkleinert oder vergrößert. [DDL19]

In dieser Arbeit soll die One-Fifth-Regel für die dynamische Anpassung der Rekombinationsrate herangezogen werden. Um nur den Rekombinationsschritt zu bewerten und nicht den Mutationsschritt, muss die Bewertung der Fitness vor der Mutation geschehen. Dementsprechend wird für die One-Fifth-Regel in dieser Arbeit direkt nach dem Rekombinationsschritt die Fitness der Eltern- mit der Fitness der Nachwuchs-Chromosomen verglichen. Anschließend wird betrachtet, ob 20% der Kinder eine bessere Fitness aufweisen als ihre Eltern. Wird dieser Wert übertroffen, wird die Rekombinationsrate mit 1,1 multipliziert, um den Erfolg des Rekombinationsschritts auszuschöpfen. Andernfalls wird die Rekombinationsrate mit 0,9 multipliziert und somit verringert.

Rekombinationsrate mit Offset

Torabi et al. beschreiben in ihrem Paper eine neue Rekombinationsstrategie [TST22]. Dabei verwenden sie einen Hyperparameter, der den *Offset der Rekombination* definieren soll. Das heißt, dass die Rekombination in ihrer Strategie in den ersten Generationen nicht angewendet wird, sondern erst zu einer bestimmten Generation beginnt. Wie dieser Hyperparameter bestimmt wurde und welche Größenordnung dieser einhalten sollte, wird in dem Paper allerdings nicht erwähnt.

Torabi et al. behaupten außerdem, dass ihre Strategie „den richtigen Kompromiss aus Exploration und Exploitation“ erreiche. [TST22] Vergleicht man diese Aussage mit der Aussage von Clegg et al., stellt man fest, dass sich diese Aussagen widersprechen [CWM07]: Während Clegg et al. vor allem in den ersten Generationen auf Rekombination setzen, da

der Rekombinationsschritt hier zu einer höheren Fitness-Konvergenz führen soll, meiden Torabi et al. in ihrer Strategie Rekombinationen in den ersten Generationen völlig.

Ein Ziel dieser Arbeit ist es herauszufinden, ob sich ein Offset in der Rekombination als sinnvoll erweist oder ob sich dieser nur für die Rekombinationsstrategie eignet, die Torabi et al. in ihrem Paper eingeführt haben.

2.4 Evolutionärer Operator: Mutation

Der zweite evolutionäre Operator ist die Mutation. Sie wird nach der Rekombination ausgeführt. Anders als bei der Rekombination werden bei der Mutation nicht zwei, sondern nur ein Chromosom einbezogen und daraus ein neues Chromosom erstellt. In diesem Prozess werden Teile des Genotyps des Chromosoms zufällig verändert, um daraus einen neuen Genotyp zu erzeugen. [Ahv+19]

Für *probabilistische Mutation* wird, vergleichbar zur Rekombinationsrate, eine Mutationsrate verwendet, um die Wahrscheinlichkeit anzugeben, mit der ein Gen mutiert wird. Dadurch kann es allerdings dazu kommen, dass das Chromosom vor und nach der Mutation zwar unterschiedliche Genotypen aufweist, sich die aktiven Knoten allerdings nicht voneinander unterscheiden. Dies hat zur Folge, dass sich der Lösungsansatz des CGPs bezüglich des Ausgangsproblems nicht ändert, obwohl bereits eine Mutation ausgeführt wurde. Die Fitness des CGPs kann sich in so einem Fall demnach nicht verbessern. Um dieses Problem in den Griff zu bekommen, wird in dieser Arbeit die *Single (Active) Mutation* herangezogen. In diesem Algorithmus werden zufällige Gene eines Chromosoms verändert, bis ein aktiver Knoten mutiert wurde. Anschließend bricht der Mutationsalgorithmus ab. [Mil20] Dies hat zusätzlich den Vorteil, dass keine Mutationsrate angepasst werden muss, was die Hyperparameteranalyse weniger rechenintensiv macht.

Die Veränderung eines Gens innerhalb der Mutation wird vorgenommen, indem das ausgewählte Zeichen des Genotyps zufällig geändert wird [Koz95]. Dies hat verschiedene Effekte für unterschiedliche Knotenarten des entsprechenden Phänotyps.

Ein Ausgangsknoten hat als relevanten Parameter nur seinen Vorgängerknoten. Wird also ein Ausgangsknoten mutiert, wird die eingehende Kante zufällig neu belegt. Dabei muss wie bei der Initialisierung beachtet werden, dass die Struktur von CGP erhalten bleibt. In dieser Arbeit werden dementsprechend nur Vorgängerknoten gewählt, deren Index kleiner ist als der mutierte Knoten.

Anders als bei Ausgangsknoten wird ein Rechenknoten durch mindestens zwei Parameter

bestimmt: ein Rechenoperator und mindestens eine Eingangskante. Welcher dieser Parameter mutiert werden soll, ist ebenfalls Zufall. Wird eine Kante verändert, gelten die gleichen Regeln wie beim Mutieren eines Ausgangsknotens. Wird der Rechenoperator mutiert, wird dieser zufällig neu aus den kodierten Rechenfunktionen gewählt. Da ein Eingangsknoten nur aus den Dateneingängen besteht und keine Parameter enthält, können diese nicht mutiert werden und werden im Mutationsschritt nicht betrachtet.

Um die Single Active Mutation anhand eines Beispiels näher zu erläutern wird folgender Gentyp eines Chromosoms aus Abbildung 2.2a erneut eingeführt. Es wird angenommen, dass dieses Chromosom durch vorherige Rekombination entstanden ist und somit im nächsten Schritt mutiert werden soll. Die folgende Abbildung 2.6 beschreibt dieses Mutationsbeispiel:

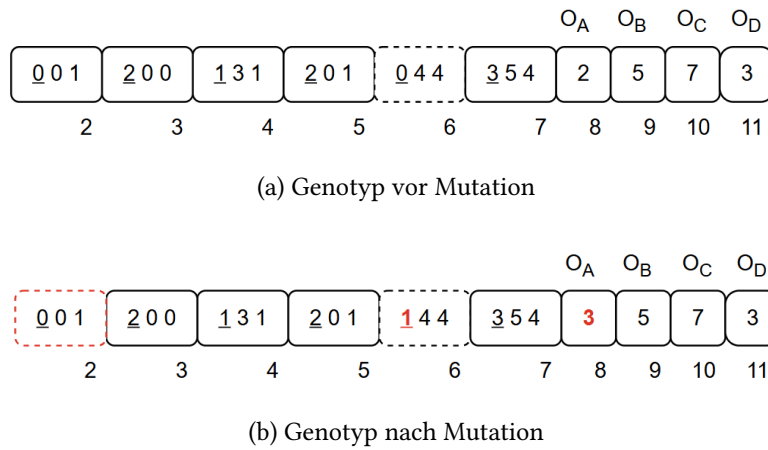


Abbildung 2.6: Single Active Mutation, angelehnt an [TST22]

Der Algorithmus beginnt und ein zufälliger Index wird für die Mutation ausgewählt. Angenommen dieser Index hat den Wert 6. Dabei handelt es sich um einen Rechenknoten. Da in diesem Beispiel die Rechenknoten jeweils 3 Parameter aufweisen, wird zufällig einer aus drei Parametern für die Mutation bestimmt. In diesem Beispiel wird der erste Parameter verändert, also der Rechenoperator. Wie bereits in Tabelle 2.1 aufgezeigt, werden die Rechenoperationen durch 0 bis 3 kodiert. Sei beispielsweise die zufällig gewählte Zahl für den Rechenoperator gleich 1. Da der in diesem Schritt mutierte Knoten inaktiv ist, muss nach der Single Active Mutation erneut mutiert werden. Angenommen der zufällig gewählte Index ist 8, was dem Index von O_A entspricht. Da es

sich, um einen Ausgangsknoten handelt, muss ein neuer Vorgängerknoten zufällig gewählt werden. Beispielsweise wird nun dieser Parameter mit dem Index 3 belegt. Da dieser Knoten Teil der aktiven Knoten ist, terminiert hier der Mutationsalgorithmus. Die Abbildung 2.6b zeigt das Ergebnis des Mutationsbeispiels (mit Kennzeichnung der neuen aktiven / inaktiven Knoten). Die mutierten Teile des Chromosoms, sowie der neu entstandene inaktive Knoten werden rot hervorgehoben.

2.5 Evaluation Fitness, Stopp-Kriterium und Ergebnis

Nachdem der Mutationsschritt für alle Chromosome der Population ausgeführt wurde, findet erneut ein Evaluationsschritt statt. Dabei wird für jedes Chromosom ein Fitness-Wert bestimmt, der bewertet wie exakt die Trainingsdaten durch das Chromosom beschrieben werden. [Ahv+19] Die Berechnung der Fitness hängt wie in Abschnitt 2.2 geschrieben vom zu lösenden Ausgangsproblem ab.

Sobald für alle Chromosome einer Population ein Fitness-Wert bestimmt wurde, werden diese auf das *Stopp-Kriterium* geprüft. Dieses gibt an, ab welcher Bedingung ein Algorithmus als konvergiert gilt. Im Beispiel von Cui et al. ist diese Bedingung bei symbolischen Regressionsbenchmarks für $Fitness < 0,01$ erfüllt. [CHH24]

Wird das Stopp-Kriterium erfüllt, wird der CGP-Algorithmus abgebrochen. Das Ergebnis ist das beste Chromosom der letzten Generation. Dieses löst das Ausgangsproblem hinreichend gut. Andernfalls wird eine weitere Iteration des CGP-Algorithmus gestartet. Dabei werden erneut Selektion, Rekombination und Mutation ausgeführt, um eine bessere Lösung des Ausgangsproblems zu finden.

2.6 Bayes'sche Analyse

Für die Evaluation der Ergebnisse werden in diesem Abschnitt statistische Grundlagen zur *Bayes'schen Analyse* erläutert.

Der Satz von Bayes (Bayes'sches Theorem) bietet Grundlagen zur Berechnung der bedingten Wahrscheinlichkeit. Zu Beginn wird eine Anfangshypothese über das Ergebnis eines Wahrscheinlichkeitsproblems angenommen. Mit zusätzlichen Informationen wird die Anfangshypothese schließlich korrigiert. Das Ergebnis ist eine neue Wahrscheinlichkeit, die alle vorhandenen Informationen einschließt. [Pey20]

Vereinfacht dargestellt funktioniert die Anwendung des Satzes von Bayes in der Bayes'schen Analyse wie in folgender Abbildung 2.7.

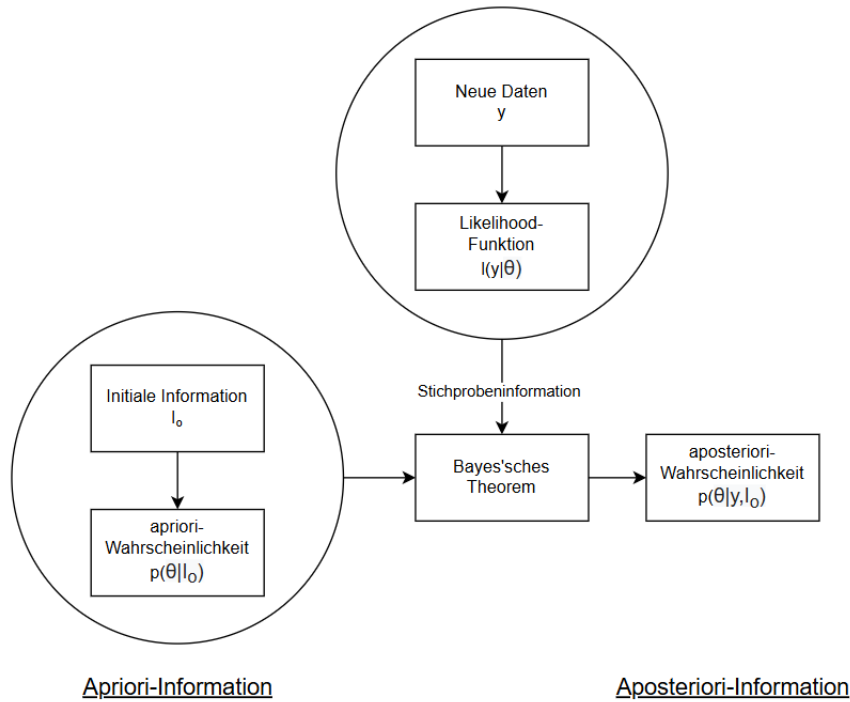


Abbildung 2.7: Bayes'sche Analyse, angelehnt an [Nen80]

Zu Beginn wird die Realität als Modell mit bestimmten Annahmen (θ) vereinfacht. Diese ursprünglichen Annahmen werden als Wahrscheinlichkeitsverteilung (*apriori-Wahrscheinlichkeit*) dargestellt. Aus den neuen Daten y kann die sogenannte *Likelihood-Funktion* errechnet werden, die eine Dichtefunktion für die Beobachtung y darstellt unter der Bedingung, dass θ zutrifft. Mit Hilfe des Bayes'schen Theorems können die apriori-Dichtefunktion und die Stichprobeninformationen miteinander verknüpft werden. Das Ergebnis ist eine neue Wahrscheinlichkeitsverteilung für θ (*aposteriori-Wahrscheinlichkeit*). [Nen80] Mit diesem Vorgehen kann also mit Hilfe von empirischen Daten eine Wahrscheinlichkeitsverteilung für ein Modell gefittet werden.

In dieser Arbeit werden basierend auf [CMH23] zwei Modelle verwendet: das *Plackett-Luce-Modell* und das *Gammaverteilung-basierte Modell*.

Mit Hilfe des Plackett-Luce-Modells können die Wahrscheinlichkeiten berechnet werden, mit denen die jeweiligen CGP-Konfigurationen besser als alle anderen Konfigurationen sind. Demnach kann eine Reihenfolge bestimmt werden, die die Effizienz der Konfigurationen sortiert angibt. Das verwendete Modell basiert auf dem Plackett-Luce-Modell, das von Calvo et al. eingeführt wird. [CMH23; CCL18]

Für die Auswertung mit Hilfe des Gammaverteilung-basierten Modells wird der Code von Pätzel verwendet ([Pät24]). Dieser ermöglicht es nicht-negative Daten zu vergleichen und daraus die Wahrscheinlichkeitsverteilung von μ_{config} zu schätzen. μ_{config} ist dabei eine zufällige Variable, die dem jeweiligen Mittelwert der Iterationenzahl entspricht, die gebraucht werden, um eine CGP-Lösung konvergieren zu lassen. Für jede CPG-Konfiguration kann so ein 95% HPDI (*highest posterior density interval*) von μ_{config} bestimmt werden. Dies bedeutet, dass innerhalb dieses Intervalls 95% der Ergebnisse liegen. [CMH23] Dadurch können die Streuungen der Iterationszahlen für jede CGP-Konfiguration miteinander verglichen werden, ohne von einer gleichverteilten Dichtefunktion ausgehen zu müssen.

Pätzel verwendet in seinem Code das *Markov Chain Monte-Carlo (MCMC) Sampling* zur Berechnung der Verteilungen [Pät24; CMH23]. Bei MCMC werden mehrere Tausend Kombinationen von Parameterwerten $(\mu_1, \sigma_1, \mu_2, \sigma_2, v)$ generiert, die jeweils zwei verschiedene Gamma-Wahrscheinlichkeitsverteilungen darstellen. Jede Wertekombination ist repräsentativ für glaubwürdige Parameterwerte, die gleichzeitig die eingehenden Daten und die vorherigen Verteilungen berücksichtigen. Diese Parameterwerte werden anschließend in zusammengefasst. [Kru12]

3 Experimente und Evaluation

3.1 Aufbau der Experimente

Für die Beantwortung der Forschungsfragen werden unterschiedliche Experimente ausgeführt, deren Ergebnisse in dieser Arbeit ausgewertet und interpretiert werden sollen. Der Programmcode für die Experimente wurde in der Sprache Julia verfasst. Dabei fand eine Orientierung an folgendem Code von Henning Cui statt: [Cui24b]

Um Ergebnisse von Ausgangsproblemen aus unterschiedlichen Domänen für eine umfangreichere Bewertung zur Verfügung zu stellen, werden mehrere Benchmark-Testszenarien überprüft. Diese werden in den folgenden Abschnitten näher betrachtet.

3.1.1 Testszenarien

Boolesche Probleme

Nach der Aussage von Kalkreuth et al. spielen *Boolesche Probleme* eine wichtige Rolle in der Forschung zu GP. Grundsätzlich ist bei Booleschen Problemen das Ziel einen sinnvollen Zusammenhang zwischen Ein- und Ausgaben zu generieren, welcher von Booleschen Funktionen bestimmt wird. Diese können wiederum durch Boolesche Ausdrücke mathematisch beschrieben werden. Die verschiedenen Booleschen Funktionen können durch Wahrheitstabellen dargestellt werden, in denen die jeweiligen Ein- und Ausgaben miteinander verknüpft werden. [Kal+23] Das Ziel von CGP-Algorithmen ist es aus Eingängen die richtigen Ausgänge zu generieren, welche dem Mapping der Boolean Funktionen entsprechen.

Insgesamt werden in dieser Arbeit zwei Boolesche Benchmarkprobleme für die Evaluation der CGP-Algorithmen betrachtet: 3-bit Parity und 16-4-bit Encode (vereinfacht bezeichnet als Parity und Encode).

Obwohl Parity als zu leichtes Ausgangsproblem für GP bezeichnet wird [Whi+13], wird es

häufig als Benchmarkproblem genutzt [YM01; KK17; KK20]. Um Benchmarkprobleme mit unterschiedlichen Ein- und Ausgangsgrößen miteinzubeziehen, wird Encode verwendet.

Das verwendete Standardfunktionsset aller Testszenarien beinhaltet die Booleschen Rechenoperatoren AND, OR, NAND und NOR. Außerdem wird die Standardfitnessfunktion für Boolesche Benchmarkprobleme verwendet. Diese wird definiert durch den Anteil an korrekt zugeordneten Bits. [CMH23] Das Stopp-Kriterium ist erfüllt, wenn die Fitness den Wert 0 erreicht. Folgend werden die beiden verwendeten Boolesche Benchmarkprobleme näher erläutert:

Parity: N-bit Parity ist eine Mapping-Funktion, die angibt, ob die Summe der Komponenten eines Binär-Vektors gerade oder ungerade ist. Bei 3-bit Parity handelt es sich dabei um Binär-Vektoren der Länge 3. Das Evaluationsset besteht aus $2^N = 2^3$ Testvektoren. [HLS99] Demnach gibt es für das CGP drei Eingaben (die Komponenten eines Binär-Vektors) und eine Ausgabe (Binärwert für „gerade“ / „ungerade“).

Encode: Beim 16-4-bit Encoding wird aus einer 16-stelligen One-Hot-Kodierung ein 4-bit Integer erstellt. Die One-Hot-Kodierung besteht dabei aus einem 16-stelligen Binär-Vektor, wobei nur eine Stelle mit einer 1 belegt ist, die restlichen Stellen sind 0. Ziel ist es diejenige Stelle zu finden, die die 1 hält und diese als üblichen 4-bit Integer zu kodieren. [Cui+23; GP15] Daraus ergibt sich eine Eingabegröße von 16 und eine Ausgabegröße von vier. Der Testdatensatz enthält 16 verschiedene One-Hot-Kodierungen, die umgewandelt werden sollen.

Symbolische Regression

Symbolische Regression (SR) zählt seit Beginn von GP als Grundlage für methodologische Forschung und als primäres Anwendungsgebiet [OLM18]. Das Ziel von SR ist das Erlernen einer Beziehung zwischen Ein- und Ausgängen nur aufgrund von gegebenen Daten. Diese Beziehung beruht auf interpretierbaren mathematischen Ausdrücken. Der Fehler von errechnetem und vorgegebenem Ausgang pro Eingang soll dabei minimiert werden. [MC24]

Die beiden in dieser Arbeit verwendeten SR Probleme werden aus dem Paper von Cui et al. übernommen: Keijzer-6 und Koza-3. Im folgenden werden diese durch Keijzer und Koza abgekürzt. Sie sind von der GP-Community empfohlen und wurden bereits in früheren Arbeiten verwendet [Whi+13; Kal20].

Der verwendete Funktionssatz besteht aus den folgenden acht mathematischen Funktionen: Addition, Subtraktion, Multiplikation, Division, Sinus, Cosinus, natürlicher Logarithmus und Exponentialfunktion. Bei der Division wird sichergestellt, dass eine Division durch null abgefangen wird. [CHH24] Dabei wird der Wert 1,0 ausgegeben, statt eine Division durch null auszuführen. Zur Absicherung des natürlichen Logarithmus werden für alle Eingaben nur die absoluten Werte in die Berechnung einbezogen. Für den Fall, dass die Eingabe gleich 0 ist, wird vergleichbar zur Division der Wert 1,0 zurückgegeben. Da es bei der Programmierung mit Julia zu Fehlern kommen kann, wenn die Eingaben von Sinus oder Cosinus zu groß sind, werden diese Fälle ebenfalls abgefangen. Dabei werden die Eingaben nicht weiter verrechnet sondern durchgereicht.

Für die Berechnung der Fitness wird der mittlere absolute Fehler zwischen vorhergesagter und tatsächlicher Ausgabe pro Eingabe berechnet. Das Stopp-Kriterium ist erfüllt, sobald die Fitness den Wert 0,01 unterschreitet. [CHH24]

Die folgende Tabelle 3.1 beschreibt die verwendeten SR Probleme näher.

Name	Variablen	Gleichung	Trainingsdaten	Testdaten
Keijzer	1	$\sum_i^x \frac{1}{i}$	E[1, 50, 1]	E[1, 120, 1]
Koza	1	$x^6 - 2 \cdot x^4 + x^2$	U[-1, 1, 20]	-

Tabelle 3.1: Beschreibung SR Benchmarkprobleme nach [CHH24]

Zu beobachten ist, dass in unterschiedlichen Papern verschiedene Keijzer-6 Funktionen beschrieben werden [Oli+18; Li+24; Kom18]. In dieser Arbeit wurden alle SR Benchmarkprobleme auf das Paper von Cui et al. bezogen [CHH24].

3.1.2 CGP-Konfigurationen

In dieser Arbeit werden unterschiedliche *CGP-Konfigurationen* miteinander verglichen und evaluiert. Diese enthalten verschiedene Parametrierungen innerhalb eines CGPs und werden in diesem Abschnitt näher erläutert.

Ein Ziel der Arbeit ist es die Effizienz von Rekombination in CGP zu bewerten. Ebenfalls sollen unterschiedliche Rekombinationsalgorithmen und -konfigurationen miteinander verglichen werden, um eine Aussage über deren Effektivität zu treffen. Aus diesem Grund müssen für die unterschiedlichen Testszenarien mehrere Rekombinationskonfigurationen getestet werden. Um eine Vergleichbarkeit der Ergebnisse zu gewährleisten müssen Selektion und Mutation in allen Experimenten gleichen Algorithmen entsprechen. Die-

se werden im Folgenden beschrieben.

Selektion: Für die Selektion wird in allen Experimenten das $(\mu+\lambda)$ -Selektionsverfahren verwendet. Dabei wurde für die CGP-Konfiguration ohne Rekombinationsschritt nicht $\mu = 1$ festgelegt, obwohl dies den Standard-Einstellungen eines CGP ohne Rekombination entspricht. Dieser zusätzliche Freiheitsgrad soll einen ausgewogeneren Vergleich zwischen den CGP-Konfigurationen mit und ohne Rekombinationsschritt ermöglichen. Für die Auswahl der Elitisten wird das neutral search Verfahren herangezogen.

Mutation: In allen Experimenten dieser Arbeit wird die Single Active Mutation angewendet.

Die nachfolgende Tabelle 3.2 gibt alle Konfigurationen für die **Rekombination** an, die für jedes Testszenario aus Abschnitt 3.1.1 getestet werden.

Rekombinationsverfahren	Art der Rekombinationsrate	Offset
One-Point Rekombination	konstante Rekombinationsrate	aktiv
Two-Point Rekombination	linear fallende Rekombinationsrate	inaktiv
Uniform Rekombination	Rekombinationsrate mit One-Fifth Regel	-
keine Rekombination	-	-

Tabelle 3.2: Konfigurationen Rekombination

Zu beachten ist, dass diese einzelnen Einstellungen miteinander kombiniert werden, solange es die Verfahren zulassen. Falls keine Rekombination ausgeführt wird, wird selbstverständlich auch die Rekombinationsrate nicht angepasst und es kann kein Offset eingeführt werden. Grundsätzlich werden die Konfigurationskombinationen nach folgendem Muster erstellt:

- Auswahl Rekombinationsverfahren
- Auswahl Art der Rekombinationsrate
- Auswahl Offset aktiv / inaktiv

Dementsprechend ergeben sich 19 verschiedene Konfigurationen für den Rekombinationsschritt, die miteinander verglichen werden sollen.

3.1.3 Hyperparameteroptimierung

Da CGP mehrere Hyperparameter ausweist, die die Effektivität eines CGP-Modells beeinflussen, muss eine *Hyperparameteroptimierung* ausgeführt werden, die einen optimierten Parametersatz ausgibt. Für jede in Abschnitt 3.1.2 eingeführte CGP-Konfiguration wird eine eigene Hyperparameteroptimierung ausgeführt, da nicht von einem optimierten Datensatz auf den nächsten geschlussfolgert werden kann. Außerdem müssen die Hyperparameter auf das jeweilige Testszenario angepasst werden.

Für die Hyperparameteroptimierungen in dieser Arbeit wird das Julia-Paket HyperOpt.jl verwendet [Car25]. Mit Hilfe des Pakets können die Hyperparameter, sowie deren Wertebereiche angegeben werden, sodass eine automatisierte Optimierung stattfinden kann. Eben diese werden in folgender Tabelle 3.3 aufgelistet.

Parameter	min	max	Schrittweite
Anzahl Rechenknoten	50	2000	50
μ (Anzahl Elitisten)	2	20	2
λ (Anzahl Nachkommen)	10	60	2
Offset Rekombination (in Iterationen)	0	P:55 / K:300	P:5 / K:30
Konstante Rekombinationsrate	0,1	1,0	0,1
Fallende Rekombinationsrate (Abzug)	0,005	0,05	0,005
One-Fifth Regel Rekombinationsrate (Startwert)	0,3	0,75	0,05

Tabelle 3.3: Optimierte Hyperparameter und deren Wertebereiche

Zu beachten ist, dass $\mu \leq \lambda$ gilt und die Hyperparameteranalysen nur für Parity und Keijzer (in Tabelle 3.3 durch P und K markiert) ausgeführt werden. Eine ausführliche Begründung liefert Abschnitt 3.1.4. Außerdem werden die Einträge der Tabelle 3.3 je nach CGP-Konfiguration verwendet. Zum Beispiel wird der Wert „Offset Rekombination“ nur verwendet, wenn der Rekombinationsoffset aktiv ist. Dieser Wert wird in Iterationen angegeben, in denen die Rekombination ausgesetzt wird. Um die obere Grenze des Offsets sinnvoll abzuschätzen wurden zuerst die Hyperparameteranalysen derjenigen CGP-Konfigurationen vorgenommen, die keinen Offset verwenden. Für jeweils ein Testszenario wurden anschließend die Mittelwerte der benötigten Iterationen berechnet. Auf Basis dieser Mittelwerte konnten die Offset Wertebereiche sinnvoller gewählt werden, sodass sich der Wert der wahrscheinlich benötigten Iterationen mit der oberen Grenze deckt. Die drei letzten Zeilen der Tabelle 3.3 geben die verschiedenen Arten an Rekombinationsraten an, die in dieser Arbeit verglichen werden. Für jede dieser Ratenarten wird gezielt nur ein Hyperparame-

ter verwendet, um die Rechenzeit der Hyperparameteroptimierung zu reduzieren. Für die linear fallende Rekombinationsrate gibt dieser Parameter an, mit welcher Schrittweite die Rekombinationsrate pro Iteration sinkt. In der One-Fifth Regel wird der Startwert der Rekombinationsrate angegeben, also diejenige Rekombinationsrate, mit der das CGP-Modell initialisiert wird.

In einer Optimierungsschleife werden pro Parametersatz 10 Testdurchläufe durchgeführt, in denen das CGP trainiert wird. Für Boolesche Probleme wird die Effizienz der Parametersätze anhand der Iterationen gemessen, die der CGP-Algorithmus braucht, bis er konvergiert. Bei symbolischer Regression bezieht sich der Vergleich auf die berechnete Fitness. Es wurde eine Iterationsgrenze eingeführt, ab der der CGP-Algorithmus in der Hyperparameteroptimierung abbricht, um Rechenzeit zu sparen. Diese Grenze wurde durch vorhergehende Tests so gesetzt, dass nur wenige Ausreißer diese überschreiten. Trifft dies zu, wird bei Booleschen Problemen die Anzahl an benötigten Iterationen verdoppelt, um so das gescheiterte Training härter zu bestrafen.

Nach 150 getesteten Parametersätzen bricht die Hyperparameteroptimierung ab und gibt den besten Parametersatz aus.

Das verwendete Julia-Paket bietet verschiedene Sampler an. Der als Standardeinstellung zur Verfügung gestellte Sampler ist ein Random-Sampler. Da der verwendete BHOB Sampler mit und ohne Hyperband keine Einsparungen in der Rechenzeit ergeben haben, wurde weiterhin der einfach zu konfigurierende Random-Sampler verwendet.

3.1.4 Teststruktur

Ursprünglich sollte für jedes Testproblem/Testscenario und für jede CGP-Konfiguration eine eigene Hyperparameteroptimierung durchgeführt werden. Mit den daraus resultierenden Parametersätzen hätten für jede Kombination aus Testscenario und CGP-Konfiguration eine annähernd optimale Lösung gefunden werden können. Diese hätten anschließend systematisch evaluiert und verglichen werden können. Angesichts der begrenzten Rechenkapazitäten konnten nur für die beiden leichtesten Testscenarien Parity und Keijzer sinnvolle Hyperparameteranalysen ausgeführt werden. Für die jeweiligen anderen Szenarien wurde deswegen eine stark vereinfachte Hyperparameterstudie ausgeführt. Hyperparameter, welche nicht die Rekombination betreffen (beispielsweise Anzahl der Rechenknoten) wurden aus der Arbeit von Cui et al. [Cui24a] herangezogen. So sollten nur die für die Rekombination relevanten Parameter optimiert werden, also die Rekombinationsrate und

gegebenenfalls der Offset. Bei den Versuchen dieses Testverfahren für die umfangreicheren Testszenarien auszuführen, wurde ebenfalls festgestellt, dass die verfügbare Rechenkapazität nicht ausreicht. Diese Beobachtung wurde auch gemacht als der Offset-Parameter bei der Optimierung vollständig herausgenommen wurde.

Aus diesen Gründen wurde eine neue Methodik entwickelt, die in diesem Abschnitt näher erläutert werden soll. Die Teststruktur wird in zwei voneinander unabhängige Testblöcke geteilt.

1. Testblock: einfache Testszenarien

Für die einfachen Testszenarien Parity und Keijzer kann eine Hyperparameteranalyse trotz eingeschränkter Rechenzeit ausgeführt werden, indem die Iterationenzahl bis zum Abbruch des CGP-Algorithmus heruntergesetzt werden. Dieser wird schrittweise reduziert, bis die Hyperparameteranalyse ausgeführt werden kann.

Um zu überprüfen, ob die angepassten Iterationsgrenzen für Parity sinnvoll sind, werden die Ergebnisse von Cui et al. herangezogen. Dabei wurden nur die Ergebnisse mit $(\mu + \lambda)$ -Selektion verwendet, die den CGP-Konfigurationen dieser Arbeit entsprechen [Cui24a]. Es ergibt sich ein HPDI-Maximalwert von ca. 495 Iterationen. Mit einer Iterationsgrenze von 500 ist es wahrscheinlich, dass vor allem schlechte Parametersätze zu einer Überschreitung dieses Werts führen. Durch die erhöhte Bestrafung dieser Überschreitung wird sichergestellt, dass die sichere Konvergenz des CGP-Algorithmus bis zur Iterationsgrenze priorisiert wird.

Da für Keijzer die Hyperparameteranalyse auf Basis der Fitness ausgewertet wird, können Güte-Aussagen ebenfalls getroffen werden, auch wenn der CGP-Algorithmus nicht vollständig konvergiert ist, da bereits vor Erreichen des Stopp-Kriteriums eine Aussage über das Konvergenzverhalten getroffen werden kann. Demnach wird für Keijzer die unter den Rechenzeit-Umständen höchste Iterationsgrenze von 500 Iterationen als genügend für die Hyperparameteroptimierung angesehen.

Mit Hilfe der optimierten Parametersätze können anschließend jeweils 50 CGP-Modelle pro Testszenario und CGP-Konfiguration ausgeführt werden. Die Ergebnisse dieser Modelle können verwendet werden, um die Güte der CGP-Konfigurationen auf einfache Testszenarien zu evaluieren. Das Evaluierungsverfahren wird in Abschnitt 3.2 näher erläutert.

2. Testblock: komplexe Testszenarien

Da sich durch die erhöhte Rechenzeit der komplexeren Testszenarien keine sinnvolle Hyperparameteroptimierung ausführen lässt, wird für diese Fälle eine andere Teststrategie entwickelt.

Diejenigen Hyperparameter eines CGP-Modells, die nicht mit Rekombination in Verbindung stehen, werden aus den Ergebnissen von Cui et al. herangezogen [Cui24a]. Die Rekombinationsrate wird variiert und mit diesen Parametern in CGP-Modelle eingepflegt. Für jede CGP-Konfiguration werden 50 Testdurchläufe ausgeführt, um eine statistische Auswertung ausführen zu können. Dabei werden die CGP-Modellen gegebenenfalls nicht bis zur vollständigen Konvergenz trainiert, um die Rechenzeit zu reduzieren. Für Boolesche Probleme werden den CGP-Modellen dabei weniger Iterationen Trainingszeit zur Verfügung gestellt als für SR Probleme. Dies ergibt sich daraus, dass Boolesche Probleme in der Hyperparameteranalyse von Cui et al. mehr Rechenknoten brauchen und somit mehr Rechenzeit für jeweils eine Iteration benötigen als es bei SR der Fall ist. [Cui24a]

Da sich die Wirkung von Rekombinationsrate und Offset gegenseitig beeinflussen kann, ist es sinnvoller die Bewertung der beiden Parameter einzeln zu betrachten. Aufgrund der hohen Anzahl der zu bewertenden Testergebnisse, die sich bereits für einen variierenden Parameter ergeben, soll nur einer dieser Parameter in dieser Arbeit näher betrachtet werden. Dieser Parameter ist wie bereits beschrieben die Rekombinationsrate. Dies ergibt sich daraus, dass die Ergebnisse der Hyperparameter- und Rohdatenanalyse der einfachen Tests bereits vermuten lassen, dass der Offset keinen deutlichen Mehrwert für das CGP-Training mit sich bringt. Details zu den jeweiligen Ergebnissen können in den Abschnitten 4.1.1 und 4.1.2 nachgelesen werden. Außerdem können mit Hilfe der Rekombinationsrate nähere Erkenntnisse zu den unterschiedlichen Rekombinationsarten gewonnen werden, die in dieser Arbeit verglichen werden.

Für die Evaluation stehen nach dem Testdurchlauf die Ergebnisse mehrerer CGP-Konfigurationen zur Verfügung, die allerdings nicht unbedingt die Ergebnisse der CGPs mit den jeweils besten Parametersätzen darstellen, da keine Hyperparameteroptimierung ausgeführt wurde. Trotzdem können die Ergebnisse verwendet werden, um einen näheren Einblick zum Verhalten des CGP-Modells zu erhalten, wenn die Rekombinationsrate variiert wird.

3.2 Evaluation

Für die Auswertung der Ergebnisse werden für jedes CGP-Training verschiedene Metriken aufgezeichnet, die einen Einblick in die Effizienz der Modelle geben sollen. Diese werden für jede Trainingsiteration gespeichert, um den Verlauf beobachten und bewerten zu können. Die folgende Liste gibt die Metriken an, die in dieser Arbeit näher betrachtet werden:

- Fitness nach Rekombination
- Fitness nach Mutation
- Anteil aktiver Knoten

Die Evaluation umfasst unterschiedliche Techniken zur Bewertung der ausgezeichneten Daten. Diese werden im Folgenden eingeführt und erläutert.

Analyse der Rohdaten: Der erste Evaluationsschritt umfasst eine händische Analyse der Rohdaten. Dabei werden die Ergebnisse der Hyperparameteranalyse näher betrachtet und bewertet. Es werden erste Erkenntnisse über die Effizienz der verschiedenen Rekombinationstypen gesammelt, indem beispielsweise die Anzahl der Rechenknoten verglichen wird. Außerdem wird beobachtet wie die unterschiedlichen Rekombinationsparameter gesetzt werden.

Des weiteren werden die Ergebnisse des CGP-Trainings näher analysiert. Der Trainingserfolg zwischen Rekombination und Mutation können anhand der jeweiligen Fitness-Werte miteinander verglichen werden.

Bayes'sche Analyse: Die Bayes'sche Analyse wird einerseits für die Sortierung der Effizienz der CGP-Konfigurationen verwendet. Dafür wird wie in Abschnitt 2.6 beschrieben das Plackett-Luce-Modell verwendet. Für die einfacheren Testszenarien Parity und Keijzer können so die Ergebnisse, der aus der Hyperparameteranalyse erhaltenen besten CGP-Konfigurationen miteinander verglichen werden.

Für weitere Bewertungen wird das Gammaverteilung-basierte genutzt. Durch die Berechnung des Mittelwerts und HPDI der Iterationen für jede CPG-Konfiguration können sowohl die einfacheren als auch die komplexeren Testszenarien ausgewertet werden. Für Parity und Keijzer kann so eingeschätzt werden, welche CGP-Konfiguration die Ausgangsprobleme schneller lösen kann als andere. Außerdem kann bewertet werden wie hoch die Streuung dieser Ergebnisse ist. Für die komplexeren Ausgangsprobleme kann beobachtet

werden, welche Auswirkungen die Änderung der Rekombinationsparameter auf die Effizienz der CGP-Modelle hat.

Die *Prior-Sensitivitätsanalyse*, die Cui et al. in ihrem Paper untersuchen, wird aus Gründen des Umfangs in dieser Arbeit nicht näher betrachtet [CMH23].

Graphische Evaluation: Für alle Testszenarien kann neben der bayes'schen Analyse eine graphische Evaluation ausgeführt werden. Dafür werden nicht die Endergebnisse des CGP-Trainings betrachtet, sondern deren Verlauf. Es werden die Fitnesswerte und Anteile der aktiven Knoten über die Iterationen hinweg geplottet. Dabei werden die Mittelwerte und Standardabweichungen der Metriken verwendet. Im Anschluss können die Plots visuell bewertet werden.

4 Ergebnisse

In den folgenden Abschnitten werden die Ergebnisse dieser Arbeit aufgezeigt und erklärt. Sie sind unterteilt in die drei Evaluations-Strategien, die in Abschnitt 3.2 erläutert wurden: Analyse der Rohdaten, bayes'sche Analyse und graphische Evaluation. Zur Vereinfachung wird die konstante Rekombinationsrate kurz „Konstant“ genannt, die linear fallende Rekombinationsrate „Clegg“ und die Rekombinationsrate mit der One-Fifth Regel „One-Fifth“.

4.1 Ergebnisse Rohdatenanalyse

Die Analyse der Rohdaten besteht aus zwei Teilen. Die Ergebnisse der Hyperparameteranalyse werden für Parity und Keijzer näher betrachtet. Es werden dabei folgende Werte für jede CGP-Konfiguration aufgezeigt:

Anzahl der Rechenknoten: Anzahl der Rechenknoten in jedem Chromosom des CGP-Modells

λ (**Nachwuchs**): Anzahl der Nachwuchs-Chromosomen in jeder Generation; λ -Wert in der $(\mu+\lambda)$ -ES

Start-Rekombinationsrate: Rekombinationsrate bei der Initialisierung; nur relevant für die konstante Rekombinationsrate und die One-Fifth Regel (linear fallende Rekombinationsrate wird mit 0,9 initialisiert)

Delta Rekombinationsrate: Dieser Wert wird bei linear fallender Rekombinationsrate in jeder Generation von der bisherigen Rekombinationsrate abgezogen.

μ (**Elitisten**): Anzahl der Elitisten in jeder Generation; μ -Wert in der $(\mu+\lambda)$ -ES

Offset: Gibt an in wie vielen Trainings-Iterationen nach Initialisierung des CGP-Modells keine Rekombination ausgeführt wird.

Des Weiteren werden für alle Testszenarien die Ergebnisse des CGP-Trainings näher betrachtet. Dabei werden die folgenden Metriken für jede CGP-Konfiguration in den Tabellen aufgezeigt:

Anzahl positive Mutationen: Gibt an wie häufig Mutation zu einer Verbesserung der Fitness geführt hat (summiert über alle 50 Durchläufe).

Anzahl positive Rekombination: Anzahl der Rekombinationsschritte, die die Fitness verbessert haben (summiert über alle 50 Durchläufe).

Anzahl negative Mutationen: Anzahl der Mutationsschritte, bei denen der vorherige Rekombinationsschritt eine Verbesserung der Fitness erzielt hat, die nach der Mutation verloren ging (summiert über alle 50 Durchläufe).

Median Iterationen positiver Rekombination: Median der Iterationen, bei denen der Rekombinationsschritt zur Verbesserung der Fitness beigetragen hat (über 50 Durchgänge hinweg)

Median Iterationen bis Konvergenz: Median der Iterationen bis das Stopp-Kriterium erfüllt wurde (über 50 Durchläufe hinweg)

Stopp-Kriterium erfüllt: Gibt an wie häufig das Stopp-Kriterium bei 50 Durchläufen erfüllt wurde. Dieser Wert wird verwendet, um Entscheidungen darüber zu treffen, wie die bayes'sche Analyse ausgeführt werden soll (für die komplexeren Testszenarien).

4.1.1 Rohdatenanalyse: Parity

Die folgende Tabelle 4.1 zeigt die Hyperparameter, die für die Ausführung des CGP-Trainings für Parity verwendet wurden. Dabei wurden die Ergebnisse der Hyperparameteranalyse verwendet, um die effizientesten CGP-Konfigurationen miteinander zu vergleichen. Zu beachten ist, dass bei der Optimierung des Rekombinations-Offsets dem Optimierer ebenfalls die Möglichkeit gegeben wurde den Offset auf 0 zu stellen und somit auszuschalten. Diese Möglichkeit wurde bei zwei aus neun CGP-Konfigurationen genutzt. Für diese Fälle aus der Hyperparameteroptimierung wurden die nächstbesten Hyperparameter gewählt, die einen Offset enthalten. Die jeweiligen Offset-Werte sind in der Tabelle rot markiert. Alle Beobachtungen in diesem Abschnitt beziehen sich ausschließlich auf das Parity-Testszenario. Demnach kann nicht grundsätzlich auf die Allgemeinheit geschlossen werden und alle Aussagen müssen kritisch begutachtet werden.

CGP-Konfigurationen	Anzahl Rechenknoten	λ (Nachwuchs)	Start-Rekombinationsrate	Delta Rekombinationsrate	μ (Elitisten)	Offset
keine Rekombination	1000	20	-	-	18	-
One-Point Konstant kein Offset	1350	52	0,30	-	16	-
One-Point Konstant mit Offset	1500	50	0,8	-	18	25
One-Point Clegg kein Offset	1950	42	-	0,035	14	-
One-Point Clegg mit Offset	1600	58	-	0,01	20	25
One-Point One-Fifth kein Offset	1150	46	0,55	-	6	-
One-Point One-Fifth mit Offset	1100	54	0,35	-	20	30
Two-Point Konstant kein Offset	1900	58	0,4	-	20	-
Two-Point Konstant mit Offset	850	54	0,3	-	16	15
Two-Point Clegg kein Offset	750	56	-	0,02	18	-
Two-Point Clegg mit Offset	1700	28	-	0,04	12	20
Two-Point One-Fifth kein Offset	1800	44	0,55	-	16	-
Two-Point One-Fifth mit Offset	950	58	0,7	-	10	15
Uniform Konstant kein Offset	1800	58	0,8	-	20	-
Uniform Konstant mit Offset	1400	54	0,3	-	20	45
Uniform Clegg kein Offset	1600	50	-	0,015	20	-
Uniform Clegg mit Offset	1500	52	-	0,04	18	25
Uniform One-Fifth kein Offset	650	52	0,75	-	14	-
Uniform One-Fifth mit Offset	250	50	0,35	-	16	40

Tabelle 4.1: Parity: Ergebnis Hyperparameteranalyse

Betrachtet wird zuerst die Anzahl der Rechenknoten. Zu beobachten ist hier, dass die CGP-Konfiguration ohne Rekombination weniger Rechenknoten benötigt als der Mittelwert aller Verfahren von ca. 1305 Rechenknoten pro Chromosom. Die Modelle, die die One-Point Rekombination verwenden, weisen mit ca 1442 den höchsten Mittelwert an Rechenkno-

ten auf. Mit durchschnittlich 1350 Rechenknoten haben die Modelle mit Two-Point Rekombination ein wenig mehr Rechenknoten benötigt als der Durchschnitt. Mit 1200 Rechenknoten im Mittel haben Modelle, die die Uniform Rekombination verwenden weniger Rechenknoten als der Durchschnitt benötigt. Da eine höhere Anzahl der Rechenknoten eine höhere Rechenzeit mit sich zieht, ist es von Vorteil diese reduzieren zu können. Unter dem Aspekt lässt sich in der Betrachtung der Hyperparameteranalyse von Parity ein Trend schätzen: wird keine Rekombination verwendet könnten Rechenzeit und Speicherressourcen gespart werden, indem weniger Rechenknoten benötigt werden. Falls Rekombination verwendet wird, könnte es sich lohnen die aufwendigeren Algorithmen zu verwenden, da es so aussieht als ob diese weniger Rechenknoten benötigen. Diese Aussagen können allerdings nicht getroffen werden, indem nur ein einzelnes Testszenario ausgewertet wird, gibt allerdings Denkanstöße für weitere Betrachtungen.

Des Weiteren fällt auf, dass die Streuung der Anzahl der Rechenknoten immer größer zu werden scheint, umso komplexer das Rekombinationsverfahren gewählt wird. Während bei One-Point Rekombination alle Werte relativ nah am Mittelwert liegen, entsteht bei Uniform Rekombination eine große Kluft zwischen extrem großen und sehr kleinen Werten. So könnte es sich im Hinblick auf die Ressourcen lohnen Rekombination einzusetzen, wenn durch eine gute Hyperparameteranalyse festgestellt werden kann, mit welcher CPG-Konfiguration das Einsparpotential am besten ausgeschöpft werden könnte. Zu beachten ist hierbei allerdings auch, dass komplexere Rekombinationsalgorithmen (und Rekombination im allgemeinen) grundsätzlich mehr Rechenzeit benötigen als wenn dieser Rekombinationsschritt ausgelassen wird. Diese Metriken müssten sinnvoll miteinander abgeglichen werden.

Wird die Populationsgröße ($\mu + \lambda$) näher betrachtet, fällt auf, dass auch hier das Verfahren ohne Rekombination eine deutlich kleinere Population benötigt als die meisten anderen. Auch dieser Faktor spart Ressourcen ein und kann für die Entscheidung für oder gegen ein Verfahren eine Rolle spielen. Die CGP-Konfiguration Two-Point Clegg mit Offset hat ebenfalls eine sehr niedrige Populationsgröße erreicht, allerdings handelt es sich bei dieser Zeile der Tabelle nicht um die beste Parametrierung der Konfiguration. Dies ist der Fall, da in dieser Zeile wie vorher beschrieben der Offset auf 0 gesetzt worden wäre, weshalb nur der zweitbeste Parametersatz gewählt wurde. Der beste Parametersatz hätte die Werte $\lambda=44$ und $\mu=12$, was wiederum eine größere Populationsgröße ergeben würde.

Bei der Begutachtung der verschiedenen Rekombinationsraten (Start-Rekombinationsrate und Delta Rekombinationsrate) können keine genauen Zusammenhänge zwischen den CGP-Konfigurationen und der Höhe der Rekombinationsraten erkannt werden. Für die Start-Rekombinationsrate kann allerdings bei allen Verfahren mit konstanter Rekombinationsrate beobachtet werden, dass extrem hohe oder sehr niedrige Rekombinationsraten vermieden werden. Für die One-Fifth Regel wurde genau dieser mittelhohe Bereich zwi-

schen 0 und 1 für die Hyperparameteranalyse freigegeben. Dieser Bereich wird nahezu vollständig in den Ergebnissen ausgenutzt. In weiteren Tests könnte überprüft werden, ob die Bereiche für den Start-Wert der Rekombinationsrate sinnvoll gewählt wurden oder ob die Hyperparameteranalyse für diese Fälle extremere Werte bevorzugen würde. Auch bei der linear fallenden Rekombinationsrate wurde nahezu der gesamte Definitionsbereich für die Hyperparameteranalyse ausgenutzt.

Zuletzt wird die Offset-Spalte betrachtet. Der Mittelwert der gewählten Offsets liegt bei ca. 27 Iterationen. Am geringsten fällt der Mittelwert für die Two-Point Rekombination aus mit einem Durchschnittswert von ca. 17. Betrachtet man nicht die nachbearbeiteten Zeilen der Hyperparameteranalyse, sondern die originalen Ergebnisse, ist der Mittelwert sogar noch kleiner mit 10 Iterationen ohne Rekombination. Im Vergleich dazu liegt die Uniform Rekombination mit durchschnittlich ca. 37 Iterationen ohne Rekombination weit darüber. Das bringt die Frage auf, ob die Uniform Rekombination weniger Effizienz bietet als beispielsweise die Two-Point Rekombination, da mehr Rekombinationsschritte eingesetzt werden. Die zwei neu eingepflegten Offset-Werte (rot) entsprechen ungefähr dem allgemeinen Mittelwert.

Die folgende Tabelle 4.2 gibt einen Einblick in die Rohdaten der CGP-Trainings. Alle CGP-Konfigurationen wurden dabei 50 mal am Parity-Datensatz getestet. Die Tabelle zeigt einige wichtige Merkmale auf, die das CGP-Training ergeben hat.

CGP-Konfigurationen	Anzahl pos. Mutationen	Anzahl pos. Rekomb.	Anzahl neg. Mutationen	Median Iter. pos. Rekomb.	Median Iter. bis Konv.
keine Rekombination	133	0	0	-	58,5
One-Point Konstant kein Offset	126	8	2	5,5	44
One-Point Konstant mit Offset	136	0	0	-	49
One-Point Clegg kein Offset	123	13	3	4	74
One-Point Clegg mit Offset	126	0	0	-	43,5
One-Point One-Fifth kein Offset	119	2	1	2	34
One-Point One-Fifth mit Offset	127	0	0	-	27,5
Two-Point Konstant kein Offset	113	10	2	3	39,5
Two-Point Konstant mit Offset	129	0	0	-	64
Two-Point Clegg kein Offset	106	20	8	6,5	40
Two-Point Clegg mit Offset	125	0	0	-	70,5
Two-Point One-Fifth kein Offset	126	4	2	3	59,5
Two-Point One-Fifth mit Offset	125	0	0	-	43
Uniform Konstant kein Offset	85	44	15	14	55
Uniform Konstant mit Offset	131	0	0	-	37,5
Uniform Clegg kein Offset	101	41	15	4	31
Uniform Clegg mit Offset	130	0	0	-	51,5
Uniform One-Fifth kein Offset	108	22	12	5	69,5
Uniform One-Fifth mit Offset	123	0	0	-	54

Tabelle 4.2: Parity: Auswertung der Rohdaten

Betrachtet man Tabelle 4.2 erkennt man, dass die Mutationsschritte deutlich häufiger zu einer Verbesserung der Fitness führen als es für die Rekombinationsschritte der Fall ist. Für die CGP-Konfigurationen mit Offset kann beobachtet werden, dass keine einzige Rekombination die Fitness verbessern konnte. Dies deutet darauf hin, dass Rekombination in den ersten Iterationen des Trainings effizienter ist, da sie eigenständig zu besserer Fitness

führt und nicht nur eine Kombination aus Rekombination und anschließender Mutation die Fitness verbessert. Um diesen Zusammenhang zu validieren, wird der Median der Iterationen betrachtet, bei denen die positiven Rekombinationen auftauchen. Wird dieser Wert mit dem Median der Iterationen bis zur Konvergenz verglichen, kann festgestellt werden, dass die Rekombination besonders in frühen Trainingsphasen einen höheren Mehrwert bringt. Für CGP-Konfigurationen mit linear fallender Rekombinationsrate werden relativ hohe Anzahlen an positiver Rekombination erreicht. Dies könnte damit zusammenhängen, dass bei der Initialisierung eine hohe Rekombinationsrate (0,9) gewählt wird und somit die Rekombination in den anfänglichen Iterationen wahrscheinlicher ausgeführt wird. Für die konstante Rekombinationsrate ist dies nicht der Fall, da die Rekombinationsrate laut Tabelle 4.1 recht niedrig gewählt wurde (0,3). Betrachtet man die Mediane der Iterationen bis zur Konvergenz, sollte dementsprechend festgestellt werden können, dass die CGP-Modelle mit linear fallender Rekombinationsrate deutlich geringere Werte aufweisen als die restlichen Modelle. Dies ist allerdings nicht Fall. Alle CGP-Modelle mit Rekombination brauchen ähnlich viele Iterationen bis zur Konvergenz unabhängig von der Rekombinationsraten-Art. Dies kann daran an mehreren Gründen liegen. Einer davon kann sein, dass der Median der Iterationen bis zur Konvergenz nur diejenigen Trainingsdurchläufe einbezieht, die das Stopp-Kriterium erfüllen. Es kann also sein, dass linear fallende Rekombinationsraten dazu führen, dass mehr Testdurchläufe konvergieren ohne dass dies in der Tabelle deutlich wird. Ein anderer Grund könnte sein, dass nicht alle positiven Rekombinationen aus Tabelle 4.2 auch in das Training des CGP-Modells einfließen. Die Spalte „Anzahl negative Mutationen“ gibt an in wie vielen Fällen eine positive Rekombination durch Mutation zerstört wurde. Dies heißt in solchen Trainingsschritten wurde durch Rekombination eine Verbesserung der Fitness bewirkt. Anschließend wurde in der gleichen Iteration ein Mutationsschritt ausgeführt, der die Fitness wieder verschlechtert. Da die Selektion der neuen Elitisten nur nach dem Mutationsschritt stattfindet, können Fortschritte aus dem Rekombinationsschritt verloren gehen. Zu beobachten ist, dass die Anzahlen der verlorenen positiven Rekombinationen höhere Werte aufweisen, wenn bereits mehr Rekombinationsschritte zu einer Verbesserung der Fitness beigetragen haben. Dies könnte ein Grund dafür sein, dass sich die Anzahl der positiven Rekombinationen nicht auf die Iterationen bis zur Konvergenz auswirkt.

Bei Verwendung der One-Fifth Regel erreichen die CGP-Modelle einen geringeren Wert an positiven Rekombinationen, was ein Zeichen dafür sein kann, dass diese Rekombinationsrate die Effizienz der Rekombination nicht sinnvoll steigert. Außerdem kann auch festgestellt werden, dass komplexere Rekombinationsalgorithmen mehr positive Rekombinationen aufweisen als die leichteren. Dies kann darauf hindeuten, dass komplexere Rekombinationsarten wie die Uniform Rekombination die Fitness mit einer höheren Wahrscheinlichkeit verbessern. Allerdings wurden für die Uniform Rekombinationen ohne Off-

set laut Tabelle 4.1 relativ hohe Rekombinationsraten gewählt, die auch einen Grund für die hohen positiven Rekombinationen darstellen könnten.

Vergleicht man den „Median Iterationen bis Konvergenz“ von CGPs ohne Rekombination mit den Durchschnittswerten pro Rekombinationsart (One-Point, Two-Point und Uniform), dann fällt auf, dass der CGPs ohne Rekombination mehr Iterationen brauchen bis sie konvergieren. Das deutet darauf hin, dass es sich lohnen könnte Rekombination anzuwenden, da diese im Durchschnitt weniger Iterationen bis zur Konvergenz benötigen. Allerdings werden hier wieder nur die Durchläufe gewertet, die das Stopp-Kriterium erreicht haben. Diese Aussage muss also mit der bayes'schen Analyse und der graphischen Analyse erneut bewertet werden.

Vorerst widersprüchlich wirken die Ergebnisse, wenn man die Auswirkungen des Offsets mit den Ergebnissen der Hyperparameteroptimierung vergleicht. Da die Offsets den Mehrwert der Rekombination blockieren besteht die Frage, wieso 7 aus 9 CGP-Konfigurationen trotzdem einen Offset verwenden sollen. Dies kann einerseits daran liegen, dass die Hyperparameteranalyse mehr Parametersätze hätte testen müssen, um auf effizientere Ergebnisse zu stoßen. Ein anderer Grund könnte sein, dass der Offset im Zusammenhang mit den negativen Mutationen steht. Es könnte sein, dass die positiven Ergebnisse der Rekombination mögliche positive Ergebnisse der Rekombination beeinflussen und anschließend (bei einer Kombination aus beiden genetischen Operatoren) eine schlechtere Fitness erzielt wird. In diesen Fällen würde die Rekombination Fortschritte bringen, wenn anschließend keine Mutation ausgeführt werden würde. Wenn aber eine Mutation ausgeführt wird, kann nicht nur der Fortschritt der Rekombination aufgehoben werden, sondern auch der potentielle Fortschritt der Mutation entfällt. Die Uniform Rekombination weist hohe Zahlen auf, wenn es um die Anzahl der negativen Mutationen geht. Werden die Ergebnisse auf der Hyperparameteranalyse in Tabelle 4.1 hinzugezogen, kann beobachtet werden, dass Uniform die höchsten Werte an Offsets aufweist. Außerdem musste keiner der Uniform-Offset-Werte korrigiert werden, da keine CGP-Konfiguration mit Uniform Rekombination den Offset anfänglich ausgesetzt hat.

4.1.2 Rohdatenanalyse: Keijzer

Die folgende Tabelle 4.3 zeigt die Ergebnisse der Hyperparameteranalyse des Keijzer-Test-szenarios. Die Umstände der Hyperparameteroptimierung sind die gleichen wie bei Parity und können in Abschnitt 4.1.1 nachgelesen werden. Wie bei den Ergebnissen bei Parity gibt es auch bei der Offset-Optimierung im Keijzer-Test-szenario zwei aus neun Fällen, bei denen der Offset ursprünglich auf 0 gesetzt wurde. Diese Parametersätze wurden durch den jeweils zweitbesten Parametersatz ersetzt und sind in der Tabelle rot markiert. Die

Beobachtungen in diesem Abschnitt beziehen sich nur auf den Keijzer-Benchmark. In Abschnitt 4.1.5 werden abschließende Erkenntnisse aus den Hyperparameteranalysen von Parity und Keijzer zusammengetragen.

CGP-Konfigurationen	Anzahl Rechenknoten	λ (Nachwuchs)	Start-Rekombinationsrate	Delta Rekombinationsrate	μ (Elitisten)	Offset
keine Rekombination	1850	44	-	-	20	-
One-Point Konstant kein Offset	600	50	0,2	-	20	-
One-Point Konstant mit Offset	1200	50	1	-	4	120
One-Point Clegg kein Offset	1100	60	-	0,05	16	-
One-Point Clegg mit Offset	850	60	-	0,005	16	300
One-Point One-Fifth kein Offset	350	34	0,75	-	18	-
One-Point One-Fifth mit Offset	2000	28	0,65	-	18	180
Two-Point Konstant kein Offset	1700	60	0,5	-	8	-
Two-Point Konstant mit Offset	600	48	0,3	-	16	180
Two-Point Clegg kein Offset	750	34	-	0,005	14	-
Two-Point Clegg mit Offset	800	36	-	0,045	20	210
Two-Point One-Fifth kein Offset	1350	40	0,35	-	20	-
Two-Point One-Fifth mit Offset	700	52	0,7	-	8	30
Uniform Konstant kein Offset	1100	52	0,8	-	8	-
Uniform Konstant mit Offset	1800	60	0,1	-	20	90
Uniform Clegg kein Offset	850	26	-	0,05	18	-
Uniform Clegg mit Offset	2000	44	-	0,05	14	180
Uniform One-Fifth kein Offset	1150	54	0,75	-	18	-
Uniform One-Fifth mit Offset	900	48	0,35	-	20	90

Tabelle 4.3: Keijzer: Ergebnis Hyperparameteranalyse

Wie bereits in Abschnitt 4.1.1 erklärt, kann eine Reduktion der Rechenknoten in einem CGP-Modell dazu führen, dass Systemressourcen und Rechenzeit gespart werden können. Dies gilt natürlich nur unter Anbetracht, dass die Effizienz des CGPs zur Berechnung der Lösung nicht darunter leidet. Wird der Mittelwert aller verwendeten Rechenknoten gebildet, liegt der Wert bei ungefähr 1305. Zu beobachten ist, dass die Anzahl der Rechenknoten beim CGP-Verfahren ohne Rekombination deutlich höher als dieser Durchschnittswert ausfällt. Alle Mittelwerte der Anzahl an Rechenknoten der einzelnen Rekombinationsalgorithmen liegen unterhalb des allgemeinen Mittelwerts. Das in diesem Sinne beste Verfahren ist in diesem Fall die Two-Point Rekombination. Dieser Rekombinationsalgorithmus braucht durchschnittlich ca. 983 Rechenknoten und liegt damit weit unter dem allgemeinen Mittelwert. Mit ca. 1117 Rechenknoten im Mittel folgt die One-Point Rekombination, während mit durchschnittlich 1300 Rechenknoten die Uniform Rekombination ungefähr dem allgemeinen Mittelwert entspricht. Bei Betrachtung der Werte fällt außerdem auf, dass die One-Point Rekombination eine sehr große Kluft zwischen höchster und niedrigster Anzahl der Rechenknoten aufweist: Einerseits wird der allgemein niedrigste Wert für die verwendeten Rechenknoten aufgezeigt (350), andererseits wird die obere Grenze ausgereizt (2000). Bei der Two-Point Rekombination kann dieser Effekt nicht beobachtet werden. Außerhalb eines Ausreißers (1700) sind alle Werte relativ ähnlich groß. Ein Hinweis darauf mit welchen Parametern diese Beobachtungen in Verbindung stehen kann anhand der Tabelle nicht getroffen werden. Weder von der Rekombinationsrate noch andere Parameter weisen offensichtliche Korrelationen auf. Dieser Aspekt könnte in weiteren Untersuchungen näher betrachtet werden.

Ein Faktor, der ebenfalls Rechenzeit einsparen kann ist die Populationsgröße ($\mu + \lambda$). Diese weisen im Keijzer-Testszenario keine deutlich ersichtlichen Zusammenhänge zu den CGP-Konfigurationen auf. Die μ - und λ -Werte weichen grundsätzlich nicht stark voneinander ab, mit einigen unregelmäßigen Schwankungen, bei denen die Werte deutlich kleiner werden. Allerdings können diese Schwankungen nicht gleichzeitig bei μ und λ festgestellt werden. Für Two-Point und Uniform Rekombination verringert sich der λ -Wert bei der linear fallenden Rekombinationsrate ohne Offset. Allerdings kann durch diese Ergebnisse nicht näher ergründet werden, ob darin ein näherer Zusammenhang liegt.

Bei den Rekombinationsraten fällt auf, dass für die Start-Rekombinationsrate der One-Fifth Regel nur sehr hohe oder sehr niedrige Raten gewählt wurden. Dies könnte darauf hindeuten, dass noch extremere Werte gewählt worden wären, wenn die Grenzen der Start-Rekombinationsrate einen größeren Spielraum zugelassen hätten. Für die One-Point und Uniform Rekombination wurden für die konstanten Start-Rekombinationsraten ebenfalls Werte nahe des Definitionsbereichs gewählt. Für die Two-Point Rekombination trifft dies nicht zu. Ebenfalls bei der linear fallenden Rekombinationsrate werden solche extremen Werte beobachtet. Zusammenfassend lässt sich also sagen, dass für das Keijzer-

TestszENARIO überwiegend die Grenzen des Definitionsbereichs als Rekombinationsraten gewählt wurden.

Die Offsets wurden durchschnittlich bei 153 Iterationen gewählt, wobei zu beachten ist, dass zwei Parametersätze ursprünglich bessere Ergebnisse erbracht hätten, ohne die Rekombination zu Beginn auszusetzen. Die in der Tabelle 4.3 rot markierten Offsets wären dementsprechend ursprünglich gleich 0 gewesen. Mit den originalen Parametersätzen wäre der Mittelwert des Offsets bei 100 gelegen. Betrachtet man die Werte der Tabelle 4.3 (mit angepassten, roten) Einträgen, fällt auf, dass der Offset-Mittelwert der CGP-Konfigurationen mit Uniform Rekombination kleiner ist als derjenige von One-Point und Two-Point Rekombination. Werden diese verbesserten Parametersätze wieder auf ihren Originalwert (0) zurückgesetzt, ändert sich dies allerdings: Dadurch wird der durchschnittliche Offset-Wert der Uniform Rekombination höher als die jeweils anderen. In diesem Fall ist der Durchschnitts-Offset der Two-Point Rekombination der geringste. Es fällt außerdem auf, dass die zweitbesten Parametersätze Offset-Werte besitzen, die deutlich höher sind, als der Mittelwert aller Offsets. Der Offset der One-Point Rekombination mit linear fallender Rekombinationsrate ist dabei sogar der maximal mögliche Offset-Wert (300). Diese extreme Schwankung der Offsets zwischen erstbestem und zweitbestem Parametersatz spricht dafür, dass die Güte eines CGPs nicht kausal mit der Höhe des Offsets zusammenhängt.

Folgend werden die Rohdaten der Keijzer-Testdurchläufe anhand von Tabelle 4.4 bewertet. Wie für Parity wurden dabei 50 Durchläufe für jede CGP-Konfiguration ausgeführt, um statistische Abweichungen einzufangen.

CGP-Konfigurationen	Anzahl pos. Mutationen	Anzahl pos. Rekomb.	Anzahl neg. Mutationen	Median Iter. pos. Rekomb.	Median Iter. bis Konv.
keine Rekombination	2260	0	0	-	624
One-Point Konstant kein Offset	1183	26	16	13	756
One-Point Konstant mit Offset	1531	0	0	-	374
One-Point Clegg kein Offset	1584	59	28	5	243
One-Point Clegg mit Offset	1534	0	0	-	396,5
One-Point One-Fifth kein Offset	1307	35	18	3	766
One-Point One-Fifth mit Offset	1776	0	0	-	229
Two-Point Konstant kein Offset	1854	79	25	15	803
Two-Point Konstant mit Offset	1361	0	0	-	548
Two-Point Clegg kein Offset	1467	106	62	18,5	735
Two-Point Clegg mit Offset	1862	0	0	-	201
Two-Point One-Fifth kein Offset	1788	17	10	4	753
Two-Point One-Fifth mit Offset	1124	0	0	-	158
Uniform Konstant kein Offset	1224	480	239	24	363
Uniform Konstant mit Offset	1890	0	0	-	260,5
Uniform Clegg kein Offset	1386	77	57	6	723
Uniform Clegg mit Offset	2232	0	0	-	385,5
Uniform One-Fifth kein Offset	1491	106	50	8	155
Uniform One-Fifth mit Offset	1749	0	0	-	445,5

Tabelle 4.4: Keijzer: Auswertung der Rohdaten

Im allgemeinen lässt sich durch die Betrachtung der Tabelle 4.4 feststellen, dass die Mutation deutlich öfter eine bessere Fitness hervorbringt als die Rekombination. Außerdem tritt keine Verbesserung der Fitness durch Rekombination ein, wenn ein Offset eingesetzt wurde. Dieser Fakt und derjenige, dass der Median der Iterationen für positive Rekombinationen deutlich geringere Werte hervorbringt als der Median der Iterationen bis zur

Konvergenz, lässt darauf schließen, dass Rekombinationsschritte zu Beginn des Trainings eine höhere Chance ausweisen die Fitness zu verbessern.

Ein Trend, der sich durch die Ergebnisse aufzeigt, ist, dass mehr positive Rekombinationen auftreten, umso komplexer die Rekombinationsarten gewählt werden. So weisen CGP-Konfigurationen mit Uniform Rekombination deutlich mehr positive Rekombinationen auf als solche mit One-Point Rekombination. Außerdem treten vermehrt negative Mutationen auf, wenn mehr positive Rekombinationen beobachtet werden können. Für die One-Point und Two-Point Rekombination führt die linear fallende Rekombinationsrate ohne Offset zu den meisten positiven Mutationen. Allerdings fällt in diesem Punkt die linear fallende Rekombinationsrate für die Uniform Rekombination am geringsten aus.

Betrachtet man den Median der Iterationen bis zur Konvergenz, weißt das CGP-Modell ohne Rekombination einen deutlich höheren Wert auf, als der Durchschnitt der Mediane pro Rekombinationsart. So benötigt die Uniform Rekombination durchschnittlich ca. 389 Iterationen im Median bis zur Konvergenz, die One-Point Rekombination ca. 461 und die Two-Point Rekombination 533. Dies kann darauf hindeuten, dass es sich im Durchschnitt lohnt Rekombination auszuführen, allerdings muss beachtet werden, dass hierbei nur die konvergierten Trainings betrachtet werden. Diese Aussage muss also in weiteren Analysen validiert werden.

Beobachtet man den Einfluss, der der Offset auf die Mediane der Iterationen bis zur Konvergenz hat, kann zusammengefasst werden, dass die meisten CGP-Konfigurationen mit Offset weniger Iterationen bis zur Konvergenz brauchen als die jeweils gleichen CGP-Konfigurationen ohne Offset. Das wirft die Frage auf, wie das überhaupt der Fall sein kann, wenn der scheinbar größte Mehrwert der Rekombination wegfällt. Zu beachten ist allerdings, dass hierbei nur die Durchläufe betrachtet werden, die das Stopp-Kriterium bereits erreicht haben. Diese Frage muss also in weiteren Analysen näher betrachtet werden.

4.1.3 Rohdatenanalyse: Encode

In diesem Abschnitt werden die Rohdaten der Encode Benchmark Tests ausgewertet. Zu beachten ist, dass sich dieser Abschnitt nur auf die Ergebnisse von Encode bezieht und alle Schlussfolgerungen und Thesen in Abschnitt 4.1.5 erneut evaluiert werden. Denkanstöße und Beobachtungen jeder Art sind in diesem Abschnitt nur auf die jeweiligen Ergebnisse von Encode bezogen und stellen keine allgemeinen Aussagen dar.

Die folgenden Tabellen 4.5, 4.6 und 4.7 stellen die Ergebnisse von jeweils 50 Testdurchläufen mit 10000 Iterationen für die unterschiedlichen CGP-Konfigurationen dar. Dabei ist jede Tabelle auf eine Rekombinationsart eingeschränkt. Ziel ist es mehr über das Zusammenspiel von Rekombinationsart und Einstellungen der Rekombinationsrate zu erfahren.

Der Offset wurde hier nicht weiter betrachtet, da die Ergebnisse von Parity und Keijzer zeigen, dass der Offset dazu führt, dass die Rekombination die Fitness des CGPs nicht verbessern kann. Außerdem schließt der Offset die Rekombination für einige Iterationen aus, was den Einblick auf die Auswirkungen der Rekombinationsraten auf den Erfolg des CGPs einschränkt. Aus diesen Gründen wurde es für sinnvoll empfunden den Offset für diesen Abschnitt auszuschließen.

CGP-Konfigurationen	Anzahl pos. Mutationen	Anzahl pos. Rekomb.	Anzahl neg. Mutationen	Median Iter. pos. Rekomb.	Median Iter. bis Konv.	Stopp-Kriterium erfüllt
keine Rekombination	1138	-	-	-	3847,5	8
One-Point Konstant: 0,125	1126	20	4	9,5	3362	9
One-Point Konstant: 0,25	1100	42	5	12,5	1963	9
One-Point Konstant: 0,375	1120	43	5	6	4578,5	8
One-Point Konstant: 0,5	1104	34	2	10	936	9
One-Point Konstant: 0,625	1096	45	4	12	3293	6
One-Point Konstant: 0,75	1103	55	11	16	1898,5	6
One-Point Konstant: 0,875	1093	59	6	15	1913	10
One-Point Konstant: 1,0	1086	58	9	8	3754,5	8
One-Point Clegg: 0,0005	1125	48	6	11	1905,5	12
One-Point Clegg: 0,0015	1062	51	5	12	2754,5	6
One-Point Clegg: 0,0025	1063	39	2	9	1530	5
One-Point Clegg: 0,0035	1114	34	2	10,5	2840,5	6
One-Point Clegg: 0,0045	1127	38	2	10	2558	9
One-Point Clegg: 0,0055	1079	55	7	9	4007,5	8
One-Point One-Fifth: 0,125	1138	19	1	7	3950	9
One-Point One-Fifth: 0,25	1135	22	3	7	4111,5	12
One-Point One-Fifth: 0,375	1155	20	1	4	1685	7
One-Point One-Fifth: 0,5	1123	26	0	5	3205	11
One-Point One-Fifth: 0,625	1100	35	3	6	3809	11
One-Point One-Fifth: 0,75	1089	25	1	6	795	7
One-Point One-Fifth: 0,875	1126	32	5	8	5213	5
One-Point One-Fifth: 1,0	1112	42	3	5,5	2863	5

Tabelle 4.5: Encode One-Point Rekombination: Auswertung der Rohdaten

CGP-Konfigurationen	Anzahl pos. Mutationen	Anzahl pos. Rekomb.	Anzahl neg. Mutationen	Median Iter. pos. Rekomb.	Median Iter. bis Konv.	Stopp-Kriterium erfüllt
keine Rekombination	1138	-	-	-	3847,5	8
Two-Point Konstant: 0,125	1044	27	2	6	4039,5	2
Two-Point Konstant: 0,25	1062	35	9	7	4292	3
Two-Point Konstant: 0,375	1076	45	4	5	1840	5
Two-Point Konstant: 0,5	1041	50	12	7,5	1666	3
Two-Point Konstant: 0,625	1050	61	15	7	7370	3
Two-Point Konstant: 0,75	1019	61	14	10	3138	1
Two-Point Konstant: 0,875	1023	73	12	9	4445	5
Two-Point Konstant: 1,0	1031	65	10	5	3476,5	6
Two-Point Clegg: 0,0005	1041	70	7	6	3383	5
Two-Point Clegg: 0,0015	1015	53	8	8	2524,5	2
Two-Point Clegg: 0,0025	1026	75	8	9	6024	3
Two-Point Clegg: 0,0035	977	64	9	7	2061	3
Two-Point Clegg: 0,0045	1046	51	9	8	2616	5
Two-Point Clegg: 0,0055	1019	52	8	9,5	3475	7
Two-Point One-Fifth: 0,125	1067	10	3	5	575	2
Two-Point One-Fifth: 0,25	1077	16	4	4	707	1
Two-Point One-Fifth: 0,375	1067	17	1	4	7538	1
Two-Point One-Fifth: 0,5	1063	24	5	5	3363	3
Two-Point One-Fifth: 0,625	1075	32	6	4	4919	5
Two-Point One-Fifth: 0,75	1078	34	8	4	1312	6
Two-Point One-Fifth: 0,875	1088	36	4	5	2529,5	6
Two-Point One-Fifth: 1,0	1049	43	7	4	1140	5

Tabelle 4.6: Encode Two-Point Rekombination: Auswertung der Rohdaten

CGP-Konfigurationen	Anzahl pos. Mutationen	Anzahl pos. Rekomb.	Anzahl neg. Mutationen	Median Iter. pos. Rekomb.	Median Iter. bis Konv.	Stopp-Kriterium erfüllt
keine Rekombination	1138	-	-	-	3847,5	8
Uniform Konstant: 0,125	1105	52	12	7	4058	9
Uniform Konstant: 0,25	1099	69	3	13	3831,5	10
Uniform Konstant: 0,375	1076	64	10	9	4071,5	6
Uniform Konstant: 0,5	1105	68	2	12,5	993,5	8
Uniform Konstant: 0,625	1099	78	3	9	1306,5	6
Uniform Konstant: 0,75	1085	81	6	10	3459	8
Uniform Konstant: 0,875	1088	83	1	10	2490,5	6
Uniform Konstant: 1,0	1081	67	5	10	4785	9
Uniform Clegg: 0,0005	1092	76	5	8	2562	13
Uniform Clegg: 0,0015	1099	78	2	10,5	1777	11
Uniform Clegg: 0,0025	1096	74	7	11	2401,5	10
Uniform Clegg: 0,0035	1095	56	4	12	4674,5	4
Uniform Clegg: 0,0045	1080	70	2	13	5118	10
Uniform Clegg: 0,0055	1122	68	10	9,5	4044,5	8
Uniform One-Fifth: 0,125	1152	18	2	6,5	3876	7
Uniform One-Fifth: 0,25	1126	25	6	6	3393	11
Uniform One-Fifth: 0,375	1128	29	2	8	988,5	6
Uniform One-Fifth: 0,5	1156	44	5	7	3968	11
Uniform One-Fifth: 0,625	1122	40	4	8	1781	7
Uniform One-Fifth: 0,75	1104	47	4	6	3385,5	12
Uniform One-Fifth: 0,875	1075	51	10	10	1831,5	6
Uniform One-Fifth: 1,0	1129	55	7	6	4972	9

Tabelle 4.7: Encode Uniform Rekombination: Auswertung der Rohdaten

Betrachtet man die drei Tabellen 4.5, 4.6 und 4.7 lässt sich feststellen, dass innerhalb der 10000 Iterationen nur die wenigsten CGP-Modelle konvergiert sind. Aus diesem Grund wird für den Encode Benchmark bei der bayes'schen Analyse die Wahrscheinlichkeitsfunktion der Fitness nach der 10000. Iteration gefittet und analysiert.

Um Zusammenhängen zwischen den CGP-Konfigurationen und der Güte der CGP-Modelle zu erforschen wurden Muster in verschiedenen Spalten der Tabellen miteinander abgeglichen. Dabei wurden die Spalten „Anzahl positive Rekombinationen“, „Anzahl negativer Mutationen“ und „Median Iterationen positive Rekombination“ mit den zwei Spalten „Median Iterationen bis Konvergenz“ und „Stopp-Kriterium erfüllt“ verglichen. Bei diesem Musterabgleich wurden kein Hinweis darauf gefunden, dass die Spalten sich gegenseitig beeinflussen.

Bei der One-Point Rekombination haben durchschnittlich ca. 8 Durchläufe das Stopp-Kriterium erfüllt, bei der Two-Point Rekombination 3,7 und bei der Uniform Rekombination 8,5. Die CGP-Modelle mit Two-Point Rekombination erfüllen damit deutlich weniger Stopp-Kriterien als die CGP-Modelle ohne Rekombination. Dies gilt nicht nur für den Durchschnitt, sondern auch jeweils für alle CGP-Konfigurationen mit Two-Point Rekombination. Vergleicht man den Durchschnitt der konvergierten CGP-Modelle für jede Rekombinationsraten-Art (konstant, linear fallend und mit One-Fifth Regel) für jede Rekombinationsart, stellt man fest, dass sich die Mittelwerte kaum voneinander unterscheiden. Beispielsweise konvergieren für die One-Point Rekombination mit konstanter Rekombinationsrate durchschnittlich 8,1 Durchläufe, bei der linear fallenden Rekombinationsrate 7,7 Durchläufe und bei der Rekombinationsrate mit One-Fifth Regel 8,4 Durchläufe. Dies gilt für alle Rekombinationsarten gleichermaßen. Auf den ersten Blick scheint es also so, als ob die Rekombinations-Arten keinen großen Unterschied zueinander aufweisen, wenn es darum geht wie schnell CGP-Modelle konvergieren. Außerdem scheint die Anzahl der positiven Rekombinationen keinen Einfluss auf die Anzahl der erfüllten Stopp-Kriterien zu haben, da bei der One-Point Rekombination mit One-Fifth Regel vergleichsweise wenig positive Rekombinationen zu einer ähnlichen Anzahl an konvergierten CGP-Modellen führt. Über diese beiden Punkte lässt sich allerdings so leicht keine Aussage machen, da nur ersichtlich ist, wie viele Durchläufe bis zur 10000. Iteration konvergieren. Es wird nicht ersichtlich wie schnell die CGP-Modelle danach konvergieren. Ein Vergleich der Rekombinationsraten-Arten für das Encode-Testszenario muss demnach später bei weiteren Analysen festgestellt werden. Für weitere Testfälle könnten mehr Erkenntnisse gewonnen werden, wenn mehr Durchgänge das Stopp-Kriterium erfüllen.

Versucht man die Anzahl der konvergenten CGP-Modelle mit der Rekombinationsrate in Verbindung zu bringen, ergeben sich folgende Erkenntnisse: Für konstante Rekombinationsraten werden bei besonders hohen Rekombinationsraten die meisten Stopp-Kriterien erfüllt. Außerdem werden hierfür in der ersten Hälfte des Definitionsbereichs (Rekombi-

nationsrate gleich 0,125-0,5) sporadisch auch Erfolge in der Konvergenz festgestellt. Für die linear fallende Rekombinationsrate werden bei besonders kleinen und großen Schrittweiten, mit denen die Rekombinationsrate verkleinert wird, eine größere Anzahl an erfüllten Stopp-Kriterien beobachtet. Für die One-Fifth Regel konnten keine Muster gefunden werden. Allerdings unterscheiden sich die Anzahlen der konvergenten Durchgänge nicht stark voneinander, was auch bedeuten kann, dass diese Schwankungen rein zufälliger Natur sind.

Die unterschiedlichen Mediane der Iterationen, bei denen die Rekombinationserfolge entstehen, unterscheiden sich nicht stark voneinander. Diese Beobachtung kann für alle CGP-Konfigurationen getroffen werden, unabhängig von welcher Rekombinationsart oder Rekombinationsraten-Art verwendet wird. Dies weist darauf hin, dass das Fenster an Iterationen, in denen die Rekombination die Fitness verbessern kann, nicht durch die Rekombinationsrate beeinflusst werden kann.

Die folgende Abbildung 4.1 beschreibt die Zusammenhänge aus Rekombinationsraten-Arten und der Anzahl positiver Rekombinationen.




Abbildung 4.1: Encode: Raten-Arten und Anzahl positive Rekombinationen

In Abbildung 4.1 kann beobachtet werden, dass für jede Rekombinationsraten-Art die Uniform Rekombination die höchsten Anzahlen an positiver Rekombination produziert. Für die konstante und linear fallende Rekombinationsrate ist die Two-Point Rekombination in dieser Hinsicht besser als die One-Point Rekombination. Auch wird ersichtlich, dass die Rekombinationsrate mit der One-Fifth Regel niedrigere Rekombinationserfolge einführt als die anderen Rekombinationsraten-Arten.

Eine höhere Rekombinationsrate bedeutet auch eine höhere Chance, dass die Rekombination ausgeführt wird und somit die Fitness verbessert. So ist es nicht überraschend, dass die

Abbildungen 4.1a und 4.1c insgesamt eine positive Steigung aufzeigen. Nicht ersichtlich ist allerdings, wieso die konstanten Rekombinationsraten gleich 1,0 weniger gute Ergebnisse liefern als die konstanten Rekombinationsraten gleich 0,875. Dies gilt für alle Rekombinationsarten mit der konstanten Rekombinationsrate.

Ebenfalls überraschend sind die kurzfristigen lokalen Maxima, die die Abbildungen 4.1a und 4.1c bei geringen Rekombinationsraten aufzeigen. Die hohen Anzahlen an positiven Rekombinationen, obwohl die Rekombination nicht wahrscheinlich ausgeführt wird, könnte darauf hindeuten, dass die ausgeführten Rekombinationsschritte effektiver waren als diejenigen Rekombinationsschritte, die häufiger ausgeführt werden.

4.1.4 Rohdatenanalyse: Koza

Die folgenden Tabellen 4.8, 4.9 und 4.10 zeigen die Rohdaten-Auswertungen des Koza-Testszenarios. Für jede CGP-Konfiguration wurden 50 Modelle innerhalb von maximal 50000 Iterationen trainiert. Jede der Tabellen stellt eine Rekombinationsart mit verschiedenen Parametrierungen der Rekombinationsraten dar. Wie in Abschnitt 4.1.3 wurde für das Koza-Testszenario der Offset als Parameter ausgestellt. Dies geht aus den Ergebnissen von Parity und Keijzer hervor, bei denen keine erfolgreichen Rekombinationsschritte ausgeführt wurden, wenn ein Offset aktiv war. Ziel des Abschnittes ist es die Zusammenhänge zwischen verschiedenen Rekombinationsraten-Arten und dem Erfolg des CGP-Trainings zu finden. Außerdem soll bestimmt werden, welche Metrik für die Auswertung der bayes'schen Analyse verwendet werden soll. In diesem Abschnitt werden nur die Ergebnisse von Koza ausgewertet und erlauben noch keine allgemeinen Aussagen. Diese werden in Abschnitt 4.1.5 ausgewertet, indem die Ergebnisse aus allen Testszenarien zusammengetragen und verglichen werden.

CGP-Konfigurationen	Anzahl pos. Mutationen	Anzahl pos. Rekomb.	Anzahl neg. Mutationen	Median Iter. pos. Rekomb.	Median Iter. bis Konv.	Stopp-Kriterium erfüllt
keine Rekombination	1157	-	-	-	208	48
One-Point Konstant: 0,125	1338	9	8	42	616	41
One-Point Konstant: 0,25	1180	23	16	7	611	45
One-Point Konstant: 0,375	1493	42	25	43	2012	47
One-Point Konstant: 0,5	1477	57	40	18	602,5	36
One-Point Konstant: 0,625	1287	48	23	82,5	2302	45
One-Point Konstant: 0,75	1423	65	43	29	989	47
One-Point Konstant: 0,875	1593	85	48	18	848	34
One-Point Konstant: 1,0	1548	136	83	73,5	667	41
One-Point Clegg: 0,0005	1460	98	56	45,5	603	43
One-Point Clegg: 0,0015	1525	78	43	12	659	40
One-Point Clegg: 0,0025	1303	52	31	7	583	41
One-Point Clegg: 0,0035	1233	61	35	6	529	42
One-Point Clegg: 0,0045	1187	62	36	10	511	44
One-Point Clegg: 0,0055	1622	50	28	9,5	1320	42
One-Point One-Fifth: 0,125	1434	2	1	1,5	462	44
One-Point One-Fifth: 0,25	1544	7	6	1	1400	44
One-Point One-Fifth: 0,375	1005	13	8	2	838,5	46
One-Point One-Fifth: 0,5	1137	14	10	2	360,5	41
One-Point One-Fifth: 0,625	1207	18	12	2	947	44
One-Point One-Fifth: 0,75	1387	17	11	3	910	43
One-Point One-Fifth: 0,875	1160	29	14	4	301	43
One-Point One-Fifth: 1,0	1393	38	25	4	568	43

Tabelle 4.8: Koza One-Point Rekombination: Auswertung der Rohdaten

CGP-Konfigurationen	Anzahl pos. Mutationen	Anzahl pos. Rekomb.	Anzahl neg. Mutationen	Median Iter. pos. Rekomb.	Median Iter. bis Konv.	Stopp-Kriterium erfüllt
keine Rekombination	1157	-	-	-	208	48
Two-Point Konstant: 0,125	1383	41	24	106	106	45
Two-Point Konstant: 0,25	1475	82	55	47,5	613	48
Two-Point Konstant: 0,375	1207	91	58	75	153	43
Two-Point Konstant: 0,5	1120	85	49	29	194	46
Two-Point Konstant: 0,625	1013	93	38	16	124	49
Two-Point Konstant: 0,75	1373	145	65	21	190	43
Two-Point Konstant: 0,875	1400	140	76	26	731	46
Two-Point Konstant: 1,0	1176	220	140	50,5	207	48
Two-Point Clegg: 0,0005	1446	193	99	30	205	47
Two-Point Clegg: 0,0015	1167	105	59	14	154	45
Two-Point Clegg: 0,0025	1396	106	53	18	504,5	44
Two-Point Clegg: 0,0035	1043	95	45	13	142	46
Two-Point Clegg: 0,0045	1023	100	50	14,5	96	46
Two-Point Clegg: 0,0055	1160	94	43	11,5	223,5	49
Two-Point One-Fifth: 0,125	1422	5	4	2	226	45
Two-Point One-Fifth: 0,25	1348	10	5	4	404,5	44
Two-Point One-Fifth: 0,375	1365	15	4	3	460	46
Two-Point One-Fifth: 0,5	1761	15	4	5	584	47
Two-Point One-Fifth: 0,625	1165	22	13	6	165	48
Two-Point One-Fifth: 0,75	1041	26	13	4	213,5	46
Two-Point One-Fifth: 0,875	1050	42	19	7	185	48
Two-Point One-Fifth: 1,0	1142	35	20	5	348	49

Tabelle 4.9: Koza Two-Point Rekombination: Auswertung der Rohdaten

CGP-Konfigurationen	Anzahl pos. Mutationen	Anzahl pos. Rekomb.	Anzahl neg. Mutationen	Median Iter. pos. Rekomb.	Median Iter. bis Konv.	Stopp-Kriterium erfüllt
keine Rekombination	1157	-	-	-	208	48
Uniform Konstant: 0,125	1178	124	75	31,5	316	44
Uniform Konstant: 0,25	1233	157	90	44	479	43
Uniform Konstant: 0,375	1166	251	132	35	257,5	47
Uniform Konstant: 0,5	1084	184	92	27,5	113	45
Uniform Konstant: 0,625	1277	295	152	31	430	47
Uniform Konstant: 0,75	1301	276	141	31	382	43
Uniform Konstant: 0,875	1102	332	181	31	467	44
Uniform Konstant: 1,0	1080	328	199	21	176	43
Uniform Clegg: 0,0005	1155	373	197	40	709	46
Uniform Clegg: 0,0015	793	259	147	17	81	48
Uniform Clegg: 0,0025	887	319	181	25	140	48
Uniform Clegg: 0,0035	1415	318	162	18	162	46
Uniform Clegg: 0,0045	1404	304	153	18	637	48
Uniform Clegg: 0,0055	1364	300	141	19	143	46
Uniform One-Fifth: 0,125	1545	12	6	5	147	41
Uniform One-Fifth: 0,25	1314	24	8	6	153	44
Uniform One-Fifth: 0,375	1384	36	14	8,5	273	47
Uniform One-Fifth: 0,5	1718	61	28	6	848	46
Uniform One-Fifth: 0,625	1244	72	35	6	363	47
Uniform One-Fifth: 0,75	1320	90	49	5	207	44
Uniform One-Fifth: 0,875	1406	92	49	9	470	46
Uniform One-Fifth: 1,0	1444	83	40	6	794,5	47

Tabelle 4.10: Koza Uniform Rekombination: Auswertung der Rohdaten

Aus den Spalten „Stopp-Kriterium erfüllt“ der drei Tabellen 4.8, 4.9 und 4.10 geht hervor, dass relativ viele Durchgänge des CGP-Trainings konvergiert sind. Deswegen wird für die bayes'sche Analyse in Abschnitt 4.2.4 die Anzahl an Iterationen bis zur Konvergenz als Metrik verwendet. Außerdem lässt sich erkennen, dass mehr Mutationen zu einer Verbesserung der Fitness geführt haben als es die Rekombinationsschritte getan haben. Gleichzeitig werden einige Erfolge der Rekombinationsschritte verloren, indem anschließend noch eine Mutation ausgeführt wurde, wie in den Spalten „Anzahl negative Mutationen“ zu sehen ist. Dies kann dadurch passieren, dass die Auswahl der Elitisten erst nach der Mutation getroffen wird und so keine Evaluation der Fitness zwischen Rekombination und Mutation stattfindet. Eine Möglichkeit dies zu beheben wäre es, die Elitisten nach der Rekombination mit den Elitisten nach der Mutation abzugleichen und so die besten Chromosomen zu verwenden, die aus beiden genetischen Operationen resultieren.

Die Rekombination ist dabei vor allem in den frühen Iterationen erfolgreich. Dabei unterscheiden sich die unterschiedlichen Rekombinationsraten-Arten. Die Rekombination mit der One-Fifth Regel weist vor allem in den ersten Iterationen Erfolge auf, mit der linear fallenden Rekombinationsrate ist der Median etwas höher und mit der konstanten Rekombinationsrate sind teilweise relativ hohe Iterationen noch erfolgreich. Für die konstante Rekombinationsrate werden diese hohen Iterationsmediane allerdings nur für die One-Point und Two-Point Rekombination gesichtet. Dabei fällt auf, dass diese späten Rekombinationserfolge im Training nicht im Zusammenhang mit der Höhe der Rekombinationsrate stehen, da einige erhöhte Werte in den Spalten „Median Iterationen positive Rekombination“ auch für kleinere Rekombinationsraten auftauchen. Außerdem kann kein Zusammenhang zwischen den Spalten „Median Iterationen positive Rekombination“ und „Median Iterationen bis Konvergenz“ gefunden werden. Das bedeutet, dass die Rekombinationserfolge nicht durch längeres Training automatisch auch zu späteren Iterationen stattfinden, sondern dass dieses Verhalten unabhängig von der Trainingsdauer auftritt. Dieses Wissen könnte genutzt werden, um so Rekombination gezielter einzusetzen. Beispielsweise könnte man die frühen Rekombinationserfolge der linear fallenden Rekombinationsrate nutzen, wobei diese ähnlich viele positive Rekombinationen aufweist wie die konstante Rekombinationsrate. So könnte man in den ersten Iterationen die Erfolge der Rekombination nutzen und anschließend die Rekombinationsrate schneller reduzieren.

Werden die Iterationen betrachtet, die die Modelle bis zur Konvergenz gebraucht haben, lässt sich feststellen, dass die CGP-Modelle mit Two-Point Rekombination durchschnittlich weniger Iterationen (278) gebraucht hat als die anderen. Darauf folgt die Uniform Rekombination (349 Iterationen) und anschließend die One-Point Rekombination (835 Iterationen). Demnach sind alle Mittelwerte der Iterationsmediane bis zur Konvergenz größer als der Median der Anzahl an Iterationen, die das CGP-Modell ohne Rekombination gebraucht hat (208). Dabei muss allerdings beachtet werden, dass bei der CGP-Konfiguration ohne

Rekombination alle Hyperparameter optimiert wurden. Demnach liefern die CGP-Modelle ohne Rekombination optimierte Ergebnisse während alle anderen CGP-Konfigurationen dieses Potential noch ausschöpfen können. Trotzdem können für einige vereinzelte CGP-Konfigurationen bereits frühere Konvergenzen bei gleicher Anzahl an erfüllten Stopp-Kriterien beobachtet werden. Ein Beispiel bietet die Konfiguration „Uniform Clegg: 0,0015“ aus Tabelle 4.10. Dies ist ein Anzeichen dafür, dass CGP-Modelle durch Rekombination effizienter werden können, wenn die Rekombination sinnvoll eingesetzt wird.

Des weiteren wurde beim Vergleich der Spalten „Anzahl positive Rekombinationen“, „Anzahl negative Mutationen“ und „Median Iterationen positive Rekombinationen“ mit den Spalten „Median Iterationen bis Konvergenz“ und „Stopp-Kriterium erfüllt“ keine zusammenhängenden Muster erkannt. Eine Möglichkeit dafür, dass die Anzahl der positiven Rekombinationen keine deutliche Veränderungen in der Effizienz des CGPs hervorruft, könnten die negativen Mutationen sein. In weiteren Tests könnte dieser Zusammenhang untersucht werden, indem keine Mutation ausgeführt wird, wenn bereits eine Rekombination die Fitness des Modells verbessert hat. So könnte überprüft werden, ob die CGP-Modelle mit mehr Rekombinationserfolgen auch bessere Ergebnisse liefern oder ob Mutationserfolge relevanter für ein erfolgreiches CGP-Training sind.

Ein weiterer Punkt der auffällt sind die relativ hohen Zahlen der negativen Mutationen im Koza-Testszenario. Dies könnte daran liegen, dass die Fitness-Werte in SR Benchmarks kontinuierlich sind, während sie in booleschen Problemen durch diskrete Werte abgebildet werden. Dadurch können auch kleinere Trainingserfolge durch Rekombination in den Tabellen abgebildet werden. Dies könnte bedeuten, dass vor allen bei SR die Evaluierung nach der Rekombination als Zwischenschritt sinnvoll sein könnte.

Um die positiven Rekombinationen zu bewerten wird folgende Abbildung 4.2 eingeführt:




Abbildung 4.2: Koza: Raten-Arten und Anzahl positive Rekombinationen

Abbildung 4.2 beschreibt die positiven Rekombinationsraten pro CGP-Konfiguration, aufgeteilt in die verschiedenen Rekombinationsraten-Arten. Dabei sind die verschiedenen Rekombinationsarten mit unterschiedlichen Farben dargestellt. Zu erkennen ist, dass die Uniform Rekombination für jede Rekombinationsraten-Art mehr positive Rekombinationen erzeugt als es die anderen Rekombinationsarten schaffen. Die Rekombination mit der One-Fifth Regel schneidet in dieser Betrachtung schlechter ab als die konstante und linear fallende Rekombinationsrate. Zu beachten ist, dass es sich dabei um eine quantitative Bewertung handelt. Es wird also nicht ersichtlich wie hoch die jeweiligen Trainingserfolge der Rekombinationen ausfallen. Es macht Sinn dies besonders für SR Benchmarks in weiteren Tests näher zu betrachten, da hier die Fitness einen kontinuierlichen Wert einnimmt und sich die Trainingserfolge stark voneinander unterscheiden können.

Für die konstante Rekombinationsrate und diejenige mit der One-Fifth Regel, werden mit höheren Rekombinationsraten auch höhere Chancen gegeben, dass eine Rekombination die Fitness verbessert. Demnach macht es Sinn, dass für höhere Rekombinationsraten die Anzahl an positiven Rekombinationen steigt, wie es in den Abbildungen 4.2a und 4.2c der Fall ist. Interessant werden demnach diejenigen lokalen Maxima, die bereits entstehen, bevor jeweils die maximale Rekombinationsrate erreicht wurde. In diesen Punkten könnte die Rekombinationsrate für diese Konfigurationen der Hyperparameter besonders gut ausfallen, da hier prozentual mehr ausgeführte Rekombinationen zu einer Verbesserung der Fitness führen.

4.1.5 Rohdatenanalyse: Zusammenfassung

Zuerst sollen die Ergebnisse der Hyperparameteranalyse von Parity und Keijzer miteinander verglichen werden, um Zusammenhänge zu erschließen und einzelne Beobachtungen validieren zu können. Die folgenden Abschnitte beziehen sich dabei auf die jeweiligen Spalten der Tabellen 4.1 und 4.3.

Rechenknoten: Bei Parity kann beobachtet werden, dass die CGP-Konfiguration ohne Rekombination am wenigsten Rechenknoten aufweist. Außerdem kann der Trend beobachtet werden, dass komplexere Rekombinationsalgorithmen durchschnittlich weniger Rechenknoten zugeschrieben bekommen als einfachere Algorithmen. Dabei ist die Streuung um den Mittelwert höher, umso komplexer die Rekombinationsalgorithmen sind. Dies könnte bedeuten, dass aus einer größeren Rechenknotenanzahl eine kleinere Streuung um diese pro Rekombinationsart folgt. Im Vergleich dazu ergeben die Ergebnisse von Keijzer ein völlig anderes Bild: gegensätzlich zu Parity hat die CGP-Konfiguration ohne Rekombination die höchste Anzahl an Rechenknoten im Vergleich zu den Mittelwerten über die unterschiedlichen Rekombinationsalgorithmen. Den bei Parity beobachteten Trend, dass

komplexere Rekombinationen eine niedrigere Anzahl an Rechenknoten erfordern könnten, kann bei Keijzer nicht bestätigt werden. Hier wird für die Uniform-Rekombination die höchste durchschnittliche Anzahl an Rechenknoten erfordert. Ebenso ergibt sich für Keijzer ein anderes Bild als bei Parity, wenn man die Streuung der Rechenknotenanzahl betrachtet: Die Two-Point Rekombination weist am wenigsten Rechenknoten auf, allerdings auch die geringste Streuung. Zusammenfassend lässt sich für die Anzahl der Rechenknoten sagen, dass Parity und Keijzer vollkommen unterschiedliche Ergebnisse liefern. Demnach können keine Aussagen getroffen werden, wie die Anzahl der Rechenknoten mit den unterschiedlichen CGP-Konfigurationen zusammenhängen. Die Möglichkeit besteht ebenfalls, dass überhaupt kein Zusammenhang zwischen diesen beiden Komponenten besteht. Durch weitere Tests könnte dies näher betrachtet werden.

Populationsgröße: Bei Betrachtung der Populationsgröße kann für Parity zusammengefasst werden, dass die CGP-Konfiguration ohne Rekombination die deutlich kleinste Populationsgröße benötigt hat. Für Keijzer konnte diese Beobachtung nicht geteilt werden. Umgekehrt konnte bei Parity nicht bestätigt werden, dass Two-Point und Uniform Rekombination mit linear fallender Rekombinationsrate ohne Offset einen geringeren λ -Wert aufweisen. Zusammenfassend lässt sich also auch für die Populationsgröße kein Zusammenhang zu den unterschiedlichen Rekombinationsarten herstellen.

Rekombinationsraten: Bei den Ergebnissen der Hyperparameteroptimierung vom Parity-Testszenario werden von konstanten Rekombinationsalgorithmen besonders hohe und besonders niedrige Rekombinationsraten vermieden. Für die linear fallende Rate und die Rekombinationsrate mit der One-Fifth Regel wird (nahezu) der gesamte Definitionsbereich genutzt. Wieder im Gegensatz dazu stehen die Ergebnisse des Keijzer-Testszenarios. Hier werden für nahezu alle CGP-Konfigurationen sehr hohe oder niedrige Werte für die Rekombinationsrate verwendet. Somit kann durch die Ergebnisse der Hyperparameteranalyse nicht bewertet werden, welche Bereiche der Rekombinationsrate besonders effektiv sind.

Offset: Bei Parity wird der geringste Offset bei der Two-Point Rekombination und der höchste Offset bei der Uniform Rekombination verwendet. Werden bei Keijzer die originalen Ergebnisse verwendet, bei denen ein Offset von 0 zugelassen wird, kann dieses Verhalten ebenfalls beobachtet werden. Dies könnte bedeuten, dass die Two-Point Rekombination effizienter ist als die Uniform Rekombination, da bei ersterem weniger Rekombinationsschritte ausgesetzt werden. Die für den Offset neu eingefügten Werte, falls ein Offset gleich 0 bestimmt wird, sind bei Parity ähnlich zum allgemeinen Mittelwert des Offsets. Ein anderes Verhalten kann für das Keijzer-Testszenario beobachtet werden, bei dem die zweitbesten Parametersätze sehr hohe Offset-Werte verwenden. Dies ergibt also einen extrem hohen Sprung im Offset zwischen erstbestem und zweitbestem Parametersatz. Das ist ein Indiz dafür, dass die Güte eines CGPs nicht kausal mit der Höhe des Offsets zusam-

menhängt.

Zu beachten ist, dass die Ergebnisse der Hyperparameteranalyse mit Vorsicht zu begutachten sind. Um die Ergebnisse und die daraus abgeleiteten Aussagen zu validieren könnte es sinnvoll sein eine umfangreichere Hyperparameteranalyse auszuführen. Diese sollte mit Hilfe von mehr Rechenkapazität ausgeführt werden, damit mehr Hyperparameter getestet werden können. Außerdem kann die Anzahl an ausgeführten CGP-Trainings pro Bewertungsschritt in der Hyperparameteranalyse höher gesetzt werden. Durch diese Schritte könnten sich die Ergebnisse von Parity und Keijzer aneinander angleichen, wodurch bessere Bewertungen stattfinden könnten. Andernfalls könnte die Aussage gestärkt werden, dass die CGP-Konfigurationen keinen Zusammenhang zur Auswahl einzelner Hyperparameter aufweisen.

Folgend sollen die Rohdatenanalysen der vier Testszenarien Parity, Keijzer, Encode und Koza zusammengefasst und miteinander verglichen werden.

Parity: - Mutation häufiger positiv als Rekombination - mit Offset keine positive Rekombination + Median Iterationen pos. Rekombinationen => Rekombination in frühen Trainingsphasen effizienter - linear fallende Rekombination bringt hohe Zahlen an pos. Rekombination (wegen hohem Startwert 0,9) - Konstante Rekombination recht niedrige Werte wegen niedriger Rekombinationsrate 0,3 - One Fifth kaum pos. Rekombinationen => könnte darauf hinweisen, dass One-Fifth keine effiziente Rekombination ergibt - komplexere Rekombinationsarten machen mehr pos. Rekombinationen => kann heißen, dass komplexere Rekombinationen mit höherer Wahrscheinlichkeit Fitness verbessern => hohe pos. Rekombinationen können aber auch von hohen Rekombinationsraten aus HPO kommen - alle Modelle ca. gleich viele Iterationen bis Konvergenz (nicht Clegg am besten wie gedacht) => bedeutet, dass Iterationen bis Konvergenz nicht mit pos. Rekombination zusammenhängt => Grund 1: Clegg könnte mehr konvergente Durchläufe haben ohne das man das sehen könnte (ist nicht in Tabelle aufgeführt) => Grund 2: negative Mutationen beeinflussen Vorteil aus pos. Rekombinationen - CGP ohne Rekombination brauchen länger bis Konvergenz (Achtung eingeschränkte Sicht, weil nur die konvergenten Iterationen einbezogen werden und nicht wie viele CGP konvergieren) => kann trotzdem darauf hinweisen, dass es sich lohnen kann Rekombination auszuführen => Bayes und Graphen müssen mehr Infos bringen - 7 aus 9 Offsets aktiviert, obwohl diese Rekombination blockieren -> wieso? => HPO hätte evtl mehr Parametersätze testen sollen => Offset im Zusammenhang mit negativen Mutationen -> negative Mutationen machen nicht nur pos. Rekombinationen kaputt, sondern verhindern auch lernen mit Mutation (also ist am Ende "keine Rekombination", weil dann wenigsten Mutation klappt) - Uniform hat viel Offset und auch viel neg. Mutation (+ Offset bei Uniform war nie gleich 0 in HPO)

TODO: Argumentation bezüglich Offset von Encode doch in praktischen Teil packen
TODO: Argumentation; dass Offset nicht so viel bringt (damit Kapitel „praktischer Teil“ darauf verweisen kann)

- HPO: mehrere Durchläufe wählen gar keinen Offset
- restliche Tests vergleichen zwischen mit Offset und ohne
- Rohdatenanalyse: Rekombinationserfolge; wenn kein Offset da ist

TODO: Wieso wurde Offset überhaupt in HPO Ergebnissen (7 aus 9) verwendet?

TODO: Encode und Koza Ergebnisse mit Vorsicht betrachten: Hier wurden für "keine Rekombination" eine HPO ausgeführt und für Rest nicht

4.2 Ergebnisse Bayes'sche Analyse

4.2.1 Bayes'sche Analyse: Parity

CPG-Konfiguration	HPDI (Iter.)	MW	PL-Platz
Parity keine Rekombination	(237,958; 541,181)	357,440	0,034518
Parity One-Point Konstant kein Offset	(72,803; 131,161)	98,059	0,072723
Parity One-Point Konstant mit Offset	(117,5867; 241,124)	168,301	0,059872
Parity One-Point Clegg kein Offset	(111,330; 204,672)	151,207	0,058134
Parity One-Point Clegg mit Offset	(136,755; 318,250)	208,318	0,064637
Parity One-Point One-Fifth kein Offset	(305,150; 879,234)	516,320	0,041265
Parity One-Point One-Fifth mit Offset	(90,584; 192,603)	132,238	0,072643
Parity Two-Point Konstant kein Offset	(161,166; 366,726)	243,306	0,056980
Parity Two-Point Konstant mit Offset	(185,680; 398,045)	271,755	0,043839
Parity Two-Point Clegg kein Offset	(143,411; 320,218)	214,015	0,055768
Parity Two-Point Clegg mit Offset	(279,211; 671,061)	429,804	0,041189
Parity Two-Point One-Fifth kein Offset	(165,870; 369,988)	247,230	0,051913
Parity Two-Point One-Fifth mit Offset	(187,841; 467,866)	294,748	0,049240
Parity Uniform Konstant kein Offset	(182,312; 414,373)	275,283	0,043305
Parity Uniform Konstant mit Offset	(158,116; 357,830)	238,048	0,060934
Parity Uniform Clegg kein Offset	(120,352; 267,732)	179,796	0,063633
Parity Uniform Clegg mit Offset	(147,184; 317,828)	215,359	0,051520
Parity Uniform One-Fifth kein Offset	(233,817; 551,718)	356,681	0,040460
Parity Uniform One-Fifth mit Offset	(211,377; 519,471)	329,524	0,037426

Tabelle 4.11: Parity: Bayes'sche Analyse

4.2.2 Bayes'sche Analyse: Keijzer

CGP-Konfiguration	HPDI (Iter.)	MW	PL-Platz
Keijzer keine Rekombination	(5446,690; 16772,637)	9551,657	0,046669
Keijzer One-Point Konstant kein Offset	(3155,154; 8685,286)	5214,911	0,056954
Keijzer One-Point Konstant mit Offset	(5791,946; 19545,587)	10837,605	0,047578
Keijzer One-Point Clegg kein Offset	(4055,470; 14388,586)	7754,999	0,053452
Keijzer One-Point Clegg mit Offset	(5182,282; 17954,643)	9757,394	0,046700
Keijzer One-Point One-Fifth kein Offset	(3746,883; 10479,686)	6233,279	0,050072
Keijzer One-Point One-Fifth mit Offset	(4972,228; 16087,780)	9402,618	0,057995
Keijzer Two-Point Konstant kein Offset	(4207,924; 13285,672)	7464,243	0,061749
Keijzer Two-Point Konstant mit Offset	(3544,144; 10355,412)	6056,680	0,064480
Keijzer Two-Point Clegg kein Offset	(5468,641; 17877,607)	10017,892	0,033887
Keijzer Two-Point Clegg mit Offset	(4105,772; 13578,136)	7663,952	0,055730
Keijzer Two-Point One-Fifth kein Offset	(4408,582; 12408,349)	7381,426	0,053392
Keijzer Two-Point One-Fifth mit Offset	(6970,619; 22911,685)	13432,511	0,052018
Keijzer Uniform Konstant kein Offset	(8010,603; 23268,991)	14688,052	0,049104
Keijzer Uniform Konstant mit Offset	(3406,437; 10751,973)	6052,727	0,069820
Keijzer Uniform Clegg kein Offset	(3856,791; 10850,478)	6440,975	0,060934
Keijzer Uniform Clegg mit Offset	(6067,492; 20498,984)	11238,547	0,043535
Keijzer Uniform One-Fifth kein Offset	(3511,828; 12119,350)	6587,897	0,070569
Keijzer Uniform One-Fifth mit Offset	(4025,084; 11844,356)	6893,370	0,025362

Tabelle 4.12: Keijzer: Bayes'sche Analyse

4.2.3 Bayes'sche Analyse: Encode

CGP-Konfiguration	HPDI (Fitn.)	MW	PL-Platz
Encode keine Rekombination	(0,02727; 0,06853)	0,04351	0,040300
Encode One-Point Konstant: 0,125	(0,02416; 0,06463)	0,03969	0,039235
Encode One-Point Konstant: 0,25	(0,02342; 0,06255)	0,03837	0,044399
Encode One-Point Konstant: 0,375	(0,02216; 0,05684)	0,036	0,052266
Encode One-Point Konstant: 0,5	(0,02581; 0,06657)	0,04185	0,041112
Encode One-Point Konstant: 0,625	(0,02703; 0,06417)	0,04188	0,039622
Encode One-Point Konstant: 0,75	(0,02484; 0,05755)	0,03791	0,047276
Encode One-Point Konstant: 0,875	(0,02311; 0,06519)	0,03911	0,042973
Encode One-Point Konstant: 1,0	(0,02634; 0,06865)	0,04257	0,040402
Encode One-Point Clegg: 0,0005	(0,01874; 0,05612)	0,03254	0,058275
Encode One-Point Clegg: 0,0015	(0,03085; 0,07312)	0,04756	0,033251
Encode One-Point Clegg: 0,0025	(0,03174; 0,07112)	0,04783	0,036894
Encode One-Point Clegg: 0,0035	(0,0259; 0,05957)	0,03961	0,043415
Encode One-Point Clegg: 0,0045	(0,02262; 0,05981)	0,03682	0,047645
Encode One-Point Clegg: 0,0055	(0,02478; 0,06459)	0,04044	0,044801
Encode One-Point One-Fifth: 0,125	(0,02234; 0,06005)	0,03702	0,048045
Encode One-Point One-Fifth: 0,25	(0,02132; 0,06241)	0,0368	0,053389
Encode One-Point One-Fifth: 0,375	(0,02423; 0,05867)	0,03784	0,049249
Encode One-Point One-Fifth: 0,5	(0,01903; 0,05371)	0,03227	0,060271
Encode One-Point One-Fifth: 0,625	(0,02184; 0,0643)	0,03777	0,045892
Encode One-Point One-Fifth: 0,75	(0,02746; 0,06625)	0,04286	0,041786
Encode One-Point One-Fifth: 0,875	(0,02436; 0,05364)	0,03622	0,049501

Tabelle 4.13: Encode One-Point Rekombination: Bayes'sche Analyse

CGP-Konfiguration	HPDI (Fitn.)	MW	PL-Platz
Encode keine Rekombination	(0,02727; 0,06853)	0,04351	0,064969
Encode Two-Point Konstant: 0,125	(0,04657; 0,08164)	0,06176	0,036705
Encode Two-Point Konstant: 0,25	(0,0417; 0,08229)	0,05853	0,038448
Encode Two-Point Konstant: 0,375	(0,03172; 0,07007)	0,04742	0,056475
Encode Two-Point Konstant: 0,5	(0,04318; 0,08532)	0,06094	0,037807
Encode Two-Point Konstant: 0,625	(0,03854; 0,07511)	0,05397	0,047998
Encode Two-Point Konstant: 0,75	(0,05211; 0,08389)	0,06618	0,035496
Encode Two-Point Konstant: 0,875	(0,03614; 0,08027)	0,05438	0,045400
Encode Two-Point Konstant: 1,0	(0,03386; 0,07925)	0,052	0,047936
Encode Two-Point Clegg: 0,0005	(0,03588; 0,07852)	0,05322	0,046264
Encode Two-Point Clegg: 0,0015	(0,0457; 0,08078)	0,06077	0,036224
Encode Two-Point Clegg: 0,0025	(0,03801; 0,07255)	0,05258	0,050576
Encode Two-Point Clegg: 0,0035	(0,04651; 0,09123)	0,06523	0,034689
Encode Two-Point Clegg: 0,0045	(0,0321; 0,07079)	0,04795	0,054090
Encode Two-Point Clegg: 0,0055	(0,03634; 0,08965)	0,0573	0,039299
Encode Two-Point One-Fifth: 0,125	(0,04561; 0,08148)	0,06082	0,042431
Encode Two-Point One-Fifth: 0,25	(0,04353; 0,0687)	0,05485	0,047932
Encode Two-Point One-Fifth: 0,375	(0,04642; 0,07558)	0,05903	0,041419
Encode Two-Point One-Fifth: 0,5	(0,03834; 0,07567)	0,0539	0,045002
Encode Two-Point One-Fifth: 0,625	(0,036; 0,07918)	0,0536	0,047777
Encode Two-Point One-Fifth: 0,75	(0,03114; 0,07277)	0,04805	0,053331
Encode Two-Point One-Fifth: 0,875	(0,03244; 0,07634)	0,05012	0,049732

Tabelle 4.14: Encode Two-Point Rekombination: Bayes'sche Analyse

CGP-Konfiguration	HPDI (Fitn.)	MW	PL-Platz
Encode keine Rekombination	(0,02727; 0,06853)	0,04351	0,037060
Encode Uniform Konstant: 0,125	(0,02473; 0,06504)	0,04031	0,038501
Encode Uniform Konstant: 0,25	(0,02356; 0,06581)	0,03963	0,040006
Encode Uniform Konstant: 0,375	(0,03039; 0,07186)	0,047	0,034479
Encode Uniform Konstant: 0,5	(0,02241; 0,05759)	0,03583	0,050278
Encode Uniform Konstant: 0,625	(0,02416; 0,05673)	0,03719	0,046887
Encode Uniform Konstant: 0,75	(0,02399; 0,06258)	0,03882	0,050394
Encode Uniform Konstant: 0,875	(0,02203; 0,05148)	0,03393	0,052041
Encode Uniform Konstant: 1,0	(0,022; 0,05696)	0,03592	0,048403
Encode Uniform Clegg: 0,0005	(0,01801; 0,0552)	0,03171	0,053799
Encode Uniform Clegg: 0,0015	(0,02101; 0,06014)	0,03576	0,052238
Encode Uniform Clegg: 0,0025	(0,01737; 0,04703)	0,02884	0,057695
Encode Uniform Clegg: 0,0035	(0,02831; 0,05921)	0,04102	0,041420
Encode Uniform Clegg: 0,0045	(0,0247; 0,06962)	0,04197	0,037226
Encode Uniform Clegg: 0,0055	(0,02211; 0,05691)	0,03563	0,044593
Encode Uniform One-Fifth: 0,125	(0,02138; 0,05172)	0,03338	0,046835
Encode Uniform One-Fifth: 0,25	(0,02075; 0,06059)	0,03566	0,046254
Encode Uniform One-Fifth: 0,375	(0,02667; 0,06216)	0,04111	0,039581
Encode Uniform One-Fifth: 0,5	(0,01608; 0,04588)	0,02738	0,063355
Encode Uniform One-Fifth: 0,625	(0,02459; 0,06074)	0,03881	0,048598
Encode Uniform One-Fifth: 0,75	(0,02107; 0,06167)	0,03642	0,042721
Encode Uniform One-Fifth: 0,875	(0,03182; 0,07718)	0,04969	0,027637

Tabelle 4.15: Encode Uniform Rekombination: Bayes'sche Analyse

4.2.4 Bayes'sche Analyse: Koza

CPG-Konfiguration	HPDI (Iter.)	MW	PL-Platz
Koza keine Rekombination	(3306,396; 9338,152)	5573,228	0,066044
Koza One-Point Konstant: 0,125	(11989,955; 39904,351)	22076,286	0,039745
Koza One-Point Konstant: 0,25	(5686,475; 17041,592)	9857,749	0,053368
Koza One-Point Konstant: 0,375	(7670,190; 19745,987)	12308,128	0,041433
Koza One-Point Konstant: 0,5	(21220,641; 77451,788)	41120,883	0,030037
Koza One-Point Konstant: 0,625	(8850,276; 22781,194)	14213,974	0,042111
Koza One-Point Konstant: 0,75	(6558,793; 17538,734)	10732,756	0,050455
Koza One-Point Konstant: 0,875	(22884,073; 83707,754)	44778,187	0,034913
Koza One-Point Konstant: 1,0	(11999,809; 40932,104)	22223,655	0,045110
Koza One-Point Clegg: 0,0005	(8804,961; 28842,331)	16070,796	0,046374
Koza One-Point Clegg: 0,0015	(12897,221; 44229,228)	24132,461	0,034105
Koza One-Point Clegg: 0,0025	(12097,518; 42109,886)	22745,754	0,042530
Koza One-Point Clegg: 0,0035	(10713,692; 36149,781)	19751,179	0,041706
Koza One-Point Clegg: 0,0045	(8152,673; 25944,800)	14620,549	0,050148
Koza One-Point Clegg: 0,0055	(10396,968; 32228,793)	18312,576	0,045403
Koza One-Point One-Fifth: 0,125	(7042,406; 22949,117)	12782,824	0,055561
Koza One-Point One-Fifth: 0,25	(8698,915; 24772,687)	14733,520	0,046146
Koza One-Point One-Fifth: 0,375	(5766,106; 16551,173)	9801,340	0,052473
Koza One-Point One-Fifth: 0,5	(10523,665; 39039,177)	20390,489	0,048112
Koza One-Point One-Fifth: 0,625	(7477,611; 22329,849)	13015,454	0,043730
Koza One-Point One-Fifth: 0,75	(9605,964; 28910,079)	16579,745	0,046481
Koza One-Point One-Fifth: 0,875	(7844,463; 27078,528)	14728,439	0,044015

Tabelle 4.16: Koza One-Point Rekombination: Bayes'sche Analyse

CPG-Konfiguration	HPDI (Iter.)	MW	PL-Platz
Koza keine Rekombination	(3306,396; 9338,152)	5573,228	0,044276
Koza Two-Point Konstant: 0,125	(5778,032; 20659,534)	11104,449	0,050079
Koza Two-Point Konstant: 0,25	(4377,352; 12699,617)	7467,417	0,043383
Koza Two-Point Konstant: 0,375	(7682,846; 29668,729)	15237,451	0,042903
Koza Two-Point Konstant: 0,5	(4545,700; 15211,867)	8448,030	0,047157
Koza Two-Point Konstant: 0,625	(2506,268; 7690,605)	4414,865	0,052680
Koza Two-Point Konstant: 0,75	(8106,535; 30489,526)	15831,484	0,036253
Koza Two-Point Konstant: 0,875	(5275,995; 16141,930)	9274,253	0,039958
Koza Two-Point Konstant: 1,0	(2467,382; 7467,193)	4300,790	0,058410
Koza Two-Point Clegg: 0,0005	(3539,092; 10910,749)	6214,133	0,046851
Koza Two-Point Clegg: 0,0015	(5136,595; 18389,726)	9803,362	0,040274
Koza Two-Point Clegg: 0,0025	(7068,983; 23388,559)	12866,463	0,039712
Koza Two-Point Clegg: 0,0035	(4920,069; 17123,138)	9196,381	0,052770
Koza Two-Point Clegg: 0,0045	(5065,402; 17637,588)	9552,405	0,049098
Koza Two-Point Clegg: 0,0055	(2005,714; 5792,200)	3420,063	0,059170
Koza Two-Point One-Fifth: 0,125	(5549,634; 19765,485)	10495,382	0,042831
Koza Two-Point One-Fifth: 0,25	(8535,956; 28712,980)	15794,048	0,033087
Koza Two-Point One-Fifth: 0,375	(6383,072; 19877,145)	11333,015	0,033814
Koza Two-Point One-Fifth: 0,5	(4715,287; 13037,660)	7854,211	0,034314
Koza Two-Point One-Fifth: 0,625	(3209,936; 9921,136)	5663,114	0,051706
Koza Two-Point One-Fifth: 0,75	(4615,524; 15765,276)	8647,855	0,047033
Koza Two-Point One-Fifth: 0,875	(2480,371; 7460,089)	4313,097	0,054242

Tabelle 4.17: Koza Two-Point Rekombination: Bayes'sche Analyse

CPG-Konfiguration	HPDI (Iter.)	MW	PL-Platz
Koza keine Rekombination	(3306,396; 9338,152)	5573,228	0,046653
Koza Uniform Konstant: 0,125	(7116,082; 25435,336)	13593,719	0,038759
Koza Uniform Konstant: 0,25	(9984,851; 33237,558)	18247,622	0,032483
Koza Uniform Konstant: 0,375	(3172,788; 9799,001)	5586,763	0,054234
Koza Uniform Konstant: 0,5	(5845,776; 21080,773)	11192,410	0,048150
Koza Uniform Konstant: 0,625	(5056,513; 15161,941)	8855,128	0,044384
Koza Uniform Konstant: 0,75	(7678,984; 28599,746)	14989,121	0,042284
Koza Uniform Konstant: 0,875	(8075,534; 25962,001)	14529,689	0,037376
Koza Uniform Konstant: 1,0	(6997,916; 26553,700)	13799,512	0,050811
Koza Uniform Clegg: 0,0005	(5887,321; 17725,061)	10263,6346	0,039935
Koza Uniform Clegg: 0,0015	(1820,854; 5880,233)	3284,824	0,070103
Koza Uniform Clegg: 0,0025	(2105,563; 6348,965)	3669,648	0,062192
Koza Uniform Clegg: 0,0035	(6267,561; 20173,041)	11336,109	0,042816
Koza Uniform Clegg: 0,0045	(3259,699; 8595,464)	5275,119	0,045873
Koza Uniform Clegg: 0,0055	(4447,802; 15210,844)	8263,146	0,047253
Koza Uniform One-Fifth: 0,125	(9555,821; 36197,611)	18956,129	0,041516
Koza Uniform One-Fifth: 0,25	(6369,195; 24041,614)	12519,802	0,045399
Koza Uniform One-Fifth: 0,375	(4284,718; 13099,952)	7548,330	0,045936
Koza Uniform One-Fifth: 0,5	(6205,669; 18180,546)	10642,776	0,039174
Koza Uniform One-Fifth: 0,625	(5184,311; 15589,695)	9047,982	0,039264
Koza Uniform One-Fifth: 0,75	(7626,548; 26532,940)	14283,760	0,040292
Koza Uniform One-Fifth: 0,875	(4522,053; 14978,774)	8243,582	0,045112

Tabelle 4.18: Koza Uniform Rekombination: Bayes'sche Analyse

4.2.5 Bayes'sche Analyse: Zusammenfassung

4.3 Ergebnisse Graphische Evaluation

4.3.1 Graphische Evaluation: Parity

4.3.2 Graphische Evaluation: Keijzer

4.3.3 Graphische Evaluation: Encode

4.3.4 Graphische Evaluation: Koza

4.3.5 Graphische Evaluation: Zusammenfassung

5 Fazit aus Ausblick

- TODO: unbedingt alte Tests löschen aus praktischem Teil
- Motivation nochmal aufgreifen und Forschungsfragen
- Forschungsfragen abschließend erneut beantworten
- Ausblick auf weitere Themen oder offene Fragen

Literatur

- [Ahv+19] Milad Taleby Ahvanooei u. a. „A Survey of Genetic Programming and Its Applications“. en. In: *KSII Transactions on Internet and Information Systems* 13.4 (Apr. 2019). ISSN: 19767277. DOI: 10.3837/tiis.2019.04.002.
- [Ara20] Lourdes Araujo. „Genetic programming for natural language processing“. en. In: *Genetic Programming and Evolvable Machines* 21.1-2 (Juni 2020), S. 11–32. ISSN: 1389-2576, 1573-7632. DOI: 10.1007/s10710-019-09361-5.
- [Car25] Fredrik Bagge Carlson. *baggepinnen/Hyperopt.jl*. original-date: 2018-08-04T11:25:52Z. Jan. 2025. URL: <https://github.com/baggepinnen/Hyperopt.jl> (besucht am 02.02.2025).
- [CCL18] Borja Calvo, Josu Ceberio und Jose A. Lozano. „Bayesian inference for algorithm ranking analysis“. In: *Proceedings of the Genetic and Evolutionary Computation Conference Companion*. GECCO '18. Kyoto, Japan: Association for Computing Machinery, 2018, S. 324–325. ISBN: 9781450357647. DOI: 10.1145/3205651.3205658.
- [CHH24] Henning Cui, Michael Heider und Jörg Hähner. „Positional Bias Does Not Influence Cartesian Genetic Programming with Crossover“. en. In: *Parallel Problem Solving from Nature – PPSN XVIII*. Hrsg. von Michael Affenzeller u. a. Bd. 15148. Series Title: Lecture Notes in Computer Science. Cham: Springer Nature Switzerland, 2024, S. 151–167. ISBN: 978-3-031-70054-5 978-3-031-70055-2. DOI: 10.1007/978-3-031-70055-2_10.
- [ČLM13] Matej Črepinšek, Shih-Hsi Liu und Marjan Mernik. „Exploration and exploitation in evolutionary algorithms: A survey“. en. In: *ACM Computing Surveys* 45.3 (Juni 2013), S. 1–33. ISSN: 0360-0300, 1557-7341. DOI: 10.1145/2480741.2480752.

- [CMH22] Henning Cui, Andreas Margraf und Jörg Hähner. „Refining Mutation Variants in Cartesian Genetic Programming“. en. In: *Bioinspired Optimization Methods and Their Applications*. Hrsg. von Marjan Mernik, Tome Eftimov und Matej Črepinšek. Bd. 13627. Series Title: Lecture Notes in Computer Science. Cham: Springer International Publishing, 2022, S. 185–200. ISBN: 978-3-031-21094-5. DOI: 10.1007/978-3-031-21094-5_14.
- [CMH23] Henning Cui, Andreas Margraf und Jörg Hähner. „Equidistant Reorder Operator for Cartesian Genetic Programming:“. en. In: *Proceedings of the 15th International Joint Conference on Computational Intelligence*. Rome, Italy: SCITEPRESS - Science und Technology Publications, 2023, S. 64–74. ISBN: 978-989-758-674-3. DOI: 10.5220/0012174100003595.
- [Cui+23] Henning Cui u. a. „Weighted Mutation of Connections To Mitigate Search Space Limitations in Cartesian Genetic Programming“. In: *Proceedings of the 17th ACM/SIGEVO Conference on Foundations of Genetic Algorithms*. FOGA ’23. Potsdam, Germany: Association for Computing Machinery, 2023, S. 50–60. ISBN: 9798400702020. DOI: 10.1145/3594805.3607130.
- [Cui24a] Henning Cui. *The Positional Bias might not Influence Cartesian Genetic Programming with Crossover*. März 2024. DOI: 10.5281/zenodo.10830014.
- [Cui24b] CuiHen. *CuiHen/CGP_with_Crossover_Strategies*. original-date: 2024-03-15T09:54:31Z. Apr. 2024. URL: https://github.com/CuiHen/CGP_with_Crossover_Strategies (besucht am 11.06.2024).
- [CWM07] Janet Clegg, James Alfred Walker und Julian Frances Miller. „A new crossover technique for Cartesian genetic programming“. en. In: *Proceedings of the 9th annual conference on Genetic and evolutionary computation*. London England: ACM, Juli 2007, S. 1580–1587. ISBN: 978-1-59593-697-4. DOI: 10.1145/1276958.1277276.
- [DDL19] Benjamin Doerr, Carola Doerr und Johannes Lengler. „Self-adjusting mutation rates with provably optimal success rules“. en. In: *Proceedings of the Genetic and Evolutionary Computation Conference*. Prague Czech Republic: ACM, Juli 2019, S. 1479–1487. ISBN: 978-1-4503-6111-8. DOI: 10.1145/3321707.3321733.
- [Dem+22] Munise Didem Demirbas u. a. „Stress Analysis of 2D-FG Rectangular Plates with Multi-Gene Genetic Programming“. en. In: *Applied Sciences* 12.16 (Aug. 2022), S. 8198. ISSN: 2076-3417. DOI: 10.3390/app12168198.

-
- [ES15] A.E. Eiben und J.E. Smith. *Introduction to Evolutionary Computing*. en. Natural Computing Series. Berlin, Heidelberg: Springer Berlin Heidelberg, 2015. ISBN: 978-3-662-44873-1 978-3-662-44874-8. DOI: 10.1007/978-3-662-44874-8.
- [GP15] Brian W. Goldman und William F. Punch. „Analysis of Cartesian Genetic Programming’s Evolutionary Mechanisms“. In: *IEEE Transactions on Evolutionary Computation* 19.3 (2015), S. 359–373. DOI: 10.1109/TEVC.2014.2324539.
- [Has+19] Ahmad Hassanat u. a. „Choosing Mutation and Crossover Ratios for Genetic Algorithms—A Review with a New Dynamic Approach“. en. In: *Information* 10.12 (Dez. 2019), S. 390. ISSN: 2078-2489. DOI: 10.3390/info10120390.
- [HLS99] Myron E Hohil, Derong Liu und Stanley H Smith. „Solving the N-bit parity problem using neural networks“. In: *Neural Networks* 12.9 (1999), S. 1321–1323. ISSN: 0893-6080. DOI: [https://doi.org/10.1016/S0893-6080\(99\)00069-6](https://doi.org/10.1016/S0893-6080(99)00069-6).
- [Kal+23] Roman Kalkreuth u. a. „Towards a General Boolean Function Benchmark Suite“. en. In: *Proceedings of the Companion Conference on Genetic and Evolutionary Computation*. Lisbon Portugal: ACM, Juli 2023, S. 591–594. ISBN: 9798400701207. DOI: 10.1145/3583133.3590685.
- [Kal20] Roman Kalkreuth. „A Comprehensive Study on Subgraph Crossover in Cartesian Genetic Programming“. en. In: *Proceedings of the 12th International Joint Conference on Computational Intelligence*. Budapest, Hungary: SCITEPRESS - Science und Technology Publications, 2020, S. 59–70. ISBN: 978-989-758-475-6. DOI: 10.5220/0010110700590070.
- [KK17] Paul Kaufmann und Roman Kalkreuth. „An empirical study on the parametrization of cartesian genetic programming“. In: *Proceedings of the Genetic and Evolutionary Computation Conference Companion*. GECCO ’17. Berlin, Germany: Association for Computing Machinery, 2017, S. 231–232. ISBN: 9781450349390. DOI: 10.1145/3067695.3075980.
- [KK20] Paul Kaufmann und Roman Kalkreuth. „On the Parameterization of Cartesian Genetic Programming“. In: *2020 IEEE Congress on Evolutionary Computation (CEC)*. 2020, S. 1–8. DOI: 10.1109/CEC48606.2020.9185492.
- [Kom18] Michael Kommenda. „Local Optimization and Complexity Control for Symbolic Regression“. Dissertation. Linz, Austria: Johannes Kepler University Linz, 2018. URL: <https://resolver.obvsg.at/urn:nbn:at:at-ubl:1-21036> (besucht am 31.01.2025).
-

- [Koz95] J. R. Koza. „Survey of genetic algorithms and genetic programming“. en. In: *Proceedings of WESCON'95*. San Francisco, CA, USA: IEEE, 1995, S. 589. ISBN: 978-0-7803-2636-1. DOI: 10.1109/WESCON.1995.485447.
- [Kra+13] Krzysztof Krawiec u. a., Hrsg. *Genetic Programming: 16th European Conference, EuroGP 2013, Vienna, Austria, April 3-5, 2013. Proceedings*. en. Bd. 7831. Lecture Notes in Computer Science. Berlin, Heidelberg: Springer Berlin Heidelberg, 2013. ISBN: 978-3-642-37206-3. DOI: 10.1007/978-3-642-37207-0.
- [Kru12] John Kruschke. „Bayesian Estimation Supersedes the t Test“. In: *Journal of experimental psychology. General* 142 (Juli 2012). DOI: 10.1037/a0029146.
- [Li+24] Yanjie Li u. a. *Generative Pre-Trained Transformer for Symbolic Regression Base In-Context Reinforcement Learning*. _eprint: 2404.06330. 2024. URL: <https://arxiv.org/abs/2404.06330>.
- [MC24] Nour Makke und Sanjay Chawla. „Interpretable scientific discovery with symbolic regression: a review“. In: *Artificial Intelligence Review* 57.1 (Jan. 2024), S. 2. ISSN: 1573-7462. DOI: 10.1007/s10462-023-10622-0.
- [Mil20] Julian Francis Miller. „Cartesian genetic programming: its status and future“. en. In: *Genetic Programming and Evolvable Machines* 21.1-2 (Juni 2020), S. 129–168. ISSN: 1389-2576, 1573-7632. DOI: 10.1007/s10710-019-09360-6.
- [MN18] Nicola Milano und Stefano Nolfi. *Scaling Up Cartesian Genetic Programming through Preferential Selection of Larger Solutions*. arXiv:1810.09485. Okt. 2018. URL: <http://arxiv.org/abs/1810.09485> (besucht am 14. 10. 2024).
- [Nen80] M. Nenning. „Bayes'sche Inferenz bei der statistischen Auswertung von Marktdaten“. In: *Zeitschrift für Operations Research* 24.8 (Dez. 1980), B259–B273. ISSN: 1432-5217. DOI: 10.1007/BF01918729.
- [Oli+18] Luiz Otavio Vilas Boas Oliveira u. a. „Analysing Symbolic Regression Benchmarks under a Meta-Learning Approach“. en. In: *Proceedings of the Genetic and Evolutionary Computation Conference Companion*. arXiv:1805.10365 [cs]. Juli 2018, S. 1342–1349. DOI: 10.1145/3205651.3208293.
- [OLM18] Patryk Orzechowski, William La Cava und Jason H. Moore. „Where are we now? a large benchmark study of recent symbolic regression methods“. In: *Proceedings of the Genetic and Evolutionary Computation Conference. GECCO '18*. Kyoto, Japan: Association for Computing Machinery, 2018, S. 1183–1190. ISBN: 9781450356183. DOI: 10.1145/3205455.3205539.

-
- [Pät24] David Pätzel. *dpaetzel/cmpbayes*. original-date: 2022-03-24T10:52:44Z. Juli 2024. URL: <https://github.com/dpaetzel/cmpbayes> (besucht am 27.01.2025).
- [Pey20] Pablo Peyrolón. „Definition des Satzes von Bayes oder das Bayes-Theorem“. de. In: *Der Satz von Bayes*. Series Title: essentials. Wiesbaden: Springer Fachmedien Wiesbaden, 2020, S. 13–21. ISBN: 978-3-658-31022-6 978-3-658-31023-3. DOI: 10.1007/978-3-658-31023-3_2.
- [PG17] G. Pavai und T. V. Geetha. „A Survey on Crossover Operators“. en. In: *ACM Computing Surveys* 49.4 (Dez. 2017), S. 1–43. ISSN: 0360-0300, 1557-7341. DOI: 10.1145/3009966.
- [SB01] S. Sette und L. Boullart. „Genetic programming: principles and applications“. en. In: *Engineering Applications of Artificial Intelligence* 14.6 (Dez. 2001), S. 727–736. ISSN: 09521976. DOI: 10.1016/S0952-1976(02)00013-1.
- [SB18] José Eduardo da Silva und Heder S. Bernardino. „Cartesian Genetic Programming with Crossover for Designing Combinational Logic Circuits“. In: *2018 7th Brazilian Conference on Intelligent Systems (BRACIS)*. Okt. 2018, S. 145–150. DOI: 10.1109/BRACIS.2018.00033.
- [Sys89] Gilbert Syswerda. „Uniform Crossover in Genetic Algorithms“. en. In: *Proceedings of the Third International Conference on Genetic Algorithms, George Mason University, Fairfax, Virginia, USA, June 1989*. Fairfax, Virginia, USA, Jan. 1989. ISBN: 1-55860-066-3. URL: https://www.researchgate.net/publication/201976488_Uniform_Crossover_in_Genetic_Algorithms (besucht am 27.12.2024).
- [TST22] Ali Torabi, Arash Sharifi und Mohammad Teshnehlab. „Using Cartesian Genetic Programming Approach with New Crossover Technique to Design Convolutional Neural Networks“. en. In: *Neural Processing Letters* (Dez. 2022). ISSN: 1370-4621, 1573-773X. DOI: 10.1007/s11063-022-11093-0.
- [Whi+13] David R. White u. a. „Better GP benchmarks: community survey results and proposals“. en. In: *Genetic Programming and Evolvable Machines* 14.1 (März 2013), S. 3–29. ISSN: 1389-2576, 1573-7632. DOI: 10.1007/s10710-012-9177-2.
- [WM08] James Alfred Walker und Julian Francis Miller. „The Automatic Acquisition, Evolution and Reuse of Modules in Cartesian Genetic Programming“. In: *IEEE Transactions on Evolutionary Computation* 12.4 (2008), S. 397–417. DOI: 10.1109/TEVC.2007.903549.
-

- [YM01] Tina Yu und Julian Miller. „Neutrality and the Evolvability of Boolean Function Landscape“. In: *Genetic Programming*. Hrsg. von Julian Miller u. a. Berlin, Heidelberg: Springer Berlin Heidelberg, 2001, S. 204–217. ISBN: 978-3-540-45355-0.

A Anhang

A.1 Plots Parity